FOLHA DE APOIO — frente

★ = já saiu no teste-modelo ou no Modelo 2 · * = fora dos slides

Tipos de variável e estatística descritiva ★

Se…	Tipo	Exemplos
categorias sem ordem	**nominal**	sexo, região, contrato, *código*
categorias com ordem	**ordinal**	satisfação b/m/a, escala 1–5, escolaridade, faixa etária
contagem (inteiros)	**discreta**	nº compras, reclamações, filhos
medição	**contínua**	€ gasto, idade, tempo

Média ou mediana?	Com extremos/assimetria → **mediana** (a média é puxada)
Quartis, AIQ	Q1/Q2/Q3 = 25/50/75% · AIQ=Q3−Q1 · **50% central entre Q1 e Q3**
Dispersão	amplitude=máx−mín · $s^2=\Sigma(x-\bar{x})^2/(n-1)$ · $s=\sqrt{s^2}$ · CV=s/x̄
Forma	cauda à direita: média>mediana>moda · histograma = quantitativa em classes; barras/circular = qualitativa
Outlier / omisso	ver **origem** (erro de registo/medição ou caso real) e **impacto**. **Não eliminar automaticamente**; não substituir sempre pela média. Inconsistências: idade −3, duplicados, unidades
Número ≠ tipo	código 1/2/3 = nominal · escala 1–5 = ordinal · nº compras = discreta

Classifique: nº de compras; satisfação baixa/média/alta; montante em €; Norte/Centro/Sul; nível de escolaridade; tempo de espera em min; método de pagamento; código postal. → discreta; ordinal; contínua; nominal; ordinal; contínua; nominal; nominal

Tempos de espera 4, 5, 6, 7, 8 e 40: média ou mediana? Média=70/6=11,7; mediana=(6+7)/2=6,5 → a média é mais influenciada pelo 40

Boxplot com Q1=1400, mediana=1600, Q3=1800: AIQ e leitura? AIQ=1800−1400=400; 50% dos clientes têm rendimento entre 1400 e 1800

Tempos de atendimento agrupados em intervalos de 5 min: que gráfico? Cliente com rendimento muito superior ao dos restantes: que fazer? **Histograma** (quantitativa em classes) · verificar a origem e o impacto antes de decidir; valores em falta: identificar, origem e impacto

Dados 2,3,3,4,5,3,6: moda, mediana, média? moda 3; ordenados 2,3,3,3,4,5,6 → mediana 3; média 26/7≈3,71

Bivariada: que medida usar? ★

X	Y	Medida	Exemplo
quant.	quant.	**Pearson**	salário×experiência; idade×rendimento
ordinal	ordinal	**Spearman**	★ satisfação 1–5 × recompra 1–5; rankings
quant.	binária	**ponto-bisserial**	satisfação×churn; rendimento×incumprimento
categ.	categ.	**χ^2 + V**	género×produto; canal×churn

r (Pearson)	−1≤r≤1 · sinal=direção · |r|=força · assume Normal · **r≈0 ⇏ sem relação** (só sem relação linear)
Spearman	usa ordens; associação monótona; robusta a outliers
Ponto-bisserial	Pearson com 0/1; inverter 0/1 → |r| igual, **sinal troca**
χ^2 independência	H0 independentes · H1 associadas · `E=lin×col/n*` · `gl=(l−1)(c−1)*` · p<0,05 rejeita H0 · E adequadas (≥5*)
V de Cramér	0≤V≤1 · **χ^2 diz SE há; V diz QUANTO** · $V=\sqrt{(\chi^2/(n\cdot\min(l-1,c-1)))}$* · p<0,001 e V=0,08 → significativa mas **fraca**
Causalidade	X→Y? Y→X? **3.º fator**? acaso. Gelados×afogamentos (temperatura); guarda-chuvas×chocolate quente (frio)

Bivariada — perguntas resolvidas ★

Canal de compra × satisfação (Baixa/Média/Alta): Loja 18, 32, 50; Online 30, 40, 30 (n=200). Formule H0 e H1, indique o teste; com p=0,002 e V=0,21, interprete.
H0: canal e satisfação independentes; H1: associação → **qui-quadrado**. Totais das colunas 48, 72, 80 → **E**=100·48/200=**24**; 36; 40 (ambas as linhas).
$\chi^2=2\cdot(6^2/24+4^2/36+10^2/40)=2\cdot(1{,}5+0{,}44+2{,}5)=$**8,89**; gl=(2−1)(3−1)=2; V=√(8,89/200)=**0,21**. p<0,05 → rejeita H0: **há associação**, **fraca a moderada**; relevância prática no contexto; sem causalidade

Género × compra: homens 80 compram, 20 não; mulheres 60 e 40. Calcule E, χ^2 e V. E=70; 30; 70; 30 → χ^2=9,52; gl=1; V=√(9,52/200)=0,22

r=0,78 entre investimento em publicidade e vendas: interprete. Pode concluir-se que a publicidade causa vendas? Associação linear **positiva e forte**: + publicidade ~ + vendas. **Não**: correlação ≠ causa (preço, sazonalidade, concorrência, mercado)

r=−0,64, p<0,001 entre tempo de espera e satisfação: direção, intensidade, significância, limite causal. Negativa (+ espera, − satisfação); moderada a forte; p<0,001 = evidência contra correlação linear nula; não prova causa nem exclui confundimento

r=0,03 (ou 0,01): pode concluir-se que não há relação? Não: só há ausência de relação **linear** (pode ser U) · **r_{pb}=−0,58 (churn=1) com satisfação:** + satisfação ⇒ − churn; inverter 0/1 → +0,58

r=0,80 entre satisfação e retenção; o diretor quer aumentar a satisfação para reter. Como responde? Estão **associadas**; não prova causa (3.º fator, causalidade inversa); precisam-se estudos adicionais

Que medida: salário e anos de experiência; ranking de satisfação e de qualidade; rendimento e incumprimento (Sim/Não); género e preferência (A, B ou C); satisfação (0–10) e churn? Pearson; Spearman; ponto-bisserial; χ^2+V; ponto-bisserial

r=0,82 (marketing/vendas) e r=−0,75 (preço/quantidade): direção e conclusão correta? positiva forte: + marketing tende a + vendas · negativa forte: + preço tende a − quantidade; em ambos, causa não se conclui

6 lojas com ranks de satisfação 1..6 e rentabilidade 2,1,4,3,5,6: associação? Rankings muito semelhantes → Spearman positivo e elevado (≈0,89*)

Frases prontas de interpretação

r	"Associação linear [positiva/negativa] [fraca/moderada/forte] (r=…): quando X sobe, Y tende a […]. p<0,05: evidência contra r=0. Não implica causalidade."
χ^2+V	"p=… < 0,05 → rejeita-se H0: há evidência de associação. V=… → intensidade [fraca/moderada/forte]; relevância prática no contexto."
Escala usada	|r|=0,78 forte · −0,64 moderada a forte · ≈0,02 nula · V=0,08 fraca · V=0,21 fraca a moderada

V/F — armadilhas (desconfia de "sempre", "causa", "prova")

Falso: associação ⇒ causa · r≈0 ⇒ sem relação · significativo ⇒ forte · padronizar elimina outliers · K-means escolhe k · silhouette máx. = grupos verdadeiros · ACS/ACM = clustering · proximidade ⇒ causa · 1.ª PC explica toda a variância · accuracy alta = bom em todos os grupos · 21% = prob. individual. **Verdadeiro:** loading = relação variável–componente · treino é otimista · inicializações diferentes → soluções diferentes

Símbolos usados (descrição das variáveis)

n nº de observações · **x̄** média · **s** desvio-padrão · **s^2** variância · **Q1/Q3** quartis · **AIQ** amplitude interquartil · **r** correlação de Pearson · **r_{pb}** ponto-bisserial · **ρ** Spearman · **O** frequência observada · **E** frequência esperada · **l, c** nº de linhas e colunas da tabela · **gl** graus de liberdade · **χ^2** estatística do qui-quadrado · **V** V de Cramér · **p** p-value · **H0/H1** hipótese nula/alternativa

*Guia para COPIAR À MÃO (o exame só permite uma folha A4 manuscrita). Fontes: slides, teste-modelo e solução, Modelo de Exame 2 e resolução, exercícios e soluções da UC. * = fora dos slides.*

FOLHA DE APOIO — verso

★ = já saiu no teste-modelo ou no Modelo 2 · * = fora dos slides

PCA / ACP ★

O que é	Reduz a dimensionalidade preservando variância · PCs = **combinações lineares** ordenadas por variância · só **quantitativas** · nº máx = p · padronizar Z=(X−x̄)/s se escalas diferentes (preço 20–1000 dominaria) · sem causalidade
Adequada?	**KMO** (0,76–0,84 = razoável/boa) + **Bartlett** H0: R=I, p<0,05 → há correlação (gl=p(p−1)/2*)
Quantas PCs?	**Kaiser λ>1** · scree (cotovelo) · % acumulada · interpretabilidade
% variância	λ/p* (Σλ=p*) · acumulada = soma
Loading / score	**loading** = variável↔componente · **score** = observação↔componente (posição)
Interpretar	mesmo sinal alto = fator **global** · sinais opostos = **contraste** · nome = interpretação · **scores próximos ⇏ semelhantes em tudo**

PCA a 4 variáveis padronizadas; KMO=0,76, Bartlett p<0,001; λ=2,60; 0,82; 0,38; 0,20; loadings da C1: qualidade 0,91, durabilidade 0,87, satisfação 0,89, preço percebido −0,72. Avalie a adequação, nº de componentes (Kaiser), % de variância de C1 e interprete C1.
KMO razoável/boa + Bartlett rejeita R=I → **adequada**. Kaiser: só 2,60>1 → **1 componente**. C1=2,60/4=**65%** (C2=20,5%; acum. 85,5%). C1 opõe qualidade/durabilidade/satisfação a preço → **"valor/qualidade global percebida"**

λ=3,18; 0,48; 0,25; 0,09: % da 1.ª, acumulada das 2 primeiras, Kaiser? KMO=0,78, Bartlett χ^2=31,42, gl=6, p<0,001? C1=**79,5%**; C1+C2=**91,5%**; Kaiser → 1 componente; PCA adequada · loadings 0,90–0,94 → "qualidade global do produto"

A 1.ª componente tem cargas altas e positivas nas 4 variáveis: o que representa? Uma limitação? V/F: (i) PCs são combinações lineares; (ii) a 1.ª PC explica sempre toda a variância; (iii) reduz dimensionalidade. Dimensão **global** de desempenho; limite: depende do significado das variáveis e cargas, sem fator causal. **V; F; V** · score positivo ⇏ valores altos em todas as variáveis

ACS / ACM ★

ACS / ACM	**ACS**: 2 categóricas (tabela de contingência) · **ACM**: várias (região, canal, plano...); quantitativas só categorizadas · **não é clustering**, não segmenta
Inércia	(χ^2 diz **se** há associação, não **onde**) afastamento da independência (=χ^2/n*) · % dim = inércia dim/total · por representar = 100% − acumulada
Categoria	**coordenada** = posição · **contribuição** = peso na dimensão · **cos²** = qualidade de representação · **longe da origem ⇏ contribui muito** · dimensão = contraste entre lados · proximidade ≠ associação direta/causal

Inércia total 0,109, dimensão 1=0,081 e dimensão 2=0,028: % da dim.1 e acumulada? Numa ACM, inércia corrigida 38,6% e 24,7%: o que fica por representar?
0,081/0,109=**74,3%**; dim.1+2=100% · 38,6+24,7=**63,3%** → **36,7%** por representar

Dim.1: Tecnologia (0,72; contrib. 31,5%), 18–34 (0,65), 50+ (−0,72), Lazer (−0,51). Interprete a dimensão. Contraste: jovens/Tecnologia vs mais velhos/Lazer · contribuição ≠ coordenada (Plano Premium: cos² 0,91 = melhor representada)

No mapa, "Premium" e "Muito satisfeito" estão próximos, afastados da origem, cos² alto; Dim.1 explica 62% da inércia. Interprete e indique 2 cautelas. Sugere associação e boa representação. Cautelas: ver **contribuições**; **38% da inércia omitida**; contexto, sem causa · "a ACM identificou segmentos" ✗ → usar clustering

Símbolos usados (descrição das variáveis)

p nº de variáveis · **X** variável original · **Z** variável padronizada · **λ** valor próprio (variância da componente) · **C1, C2** componentes · **R** matriz de correlações · **a(i)** distância média da observação i ao seu cluster · **b(i)** distância média ao cluster mais próximo · **s(i)** silhouette · **k, K** nº de clusters/grupos · **D** função discriminante (a_0 constante, a_j coeficientes) · **TP/FN/FP/TN** verdadeiros positivos, falsos negativos, falsos positivos, verdadeiros negativos · **N** total

Clustering ★

O que é	grupos **desconhecidos** (não supervisionado) · distâncias: euclidiana √Σ(p−q)² · Manhattan Σ|p−q| · Chebyshev máx|p−q| · matching (categ.) · Hamming (binárias) · padronizar: escala sim, **outliers não**
Hierárquico ★	aglomerativo: cada observação começa num cluster → agrega os mais próximos até 1 · dendrograma: altura = distância, corte → k (escolhido *depois*) · ligação: simples=mín · completa=máx · **Ward**=menor aumento de variância interna
K-means	k prévio → centros iniciais → atribuir ao mais próximo → recalcular → repetir · inicializações diferentes → soluções diferentes · numérico
Silhouette ★	s=(b−a)/máx(a,b): ≈1 bem integrada · ≈0 fronteira · <0 mal atribuída · escolher k: silhouette máx. e tamanho do menor cluster + estabilidade + interpretabilidade · **limites do K-means ★:** k prévio · inicialização · outliers/escala · clusters compactos de tamanho semelhante

Silhouette K=2/3/4 = 0,44/0,61/0,52: que K? Solução com 0,43/0,57/0,49 e menor cluster 38%/18%/4%? K=3 (maior silhouette) · K=3 (0,57; menor cluster 18%); K=4 tem cluster de 4% · grupos de 120, 110 e 3 obs. → não escolher só pela silhouette

Observação com a(i)=3 e b(i)=6: silhouette? E a=5, b=2?
(6−3)/6=**0,5** (bem integrada) · (2−5)/5=−0,6 (mal atribuída)

Distâncias entre p=(1,0,2) e q=(6,0,3)? Manhattan 5+0+1=**6**; euclidiana √26≈**5,10**; Chebyshev **5** · matching (Verm.,Peq.,Gás)/(Azul,Peq.,Elétr.)=**2/3** · Hamming (1,0,1,1)/(1,1,0,1)=**2** · dendrograma de 8 clientes: 8 grupos no início; corte em 2 → {A,B,C,D},{E,F,G,H}

Clusters de 80, 120 e 100 clientes com abandono de 7,5%, 10% e 21% (p=0,012). Abandono é variável interna ou externa? Cluster 3 = maior risco individual? Externa (não usada no clustering); há associação; **não**: 21% é a taxa do grupo, não o risco de cada cliente; não prova causa

Discriminante e matriz de confusão ★

O que é	grupos **conhecidos** (supervisionada): **classifica** em grupos definidos (≠ clustering; ≠ PCA) · $D=a_0+a_1X_1+\ldots$ · D>corte → G1 · nº máx. funções **min(p,K−1)** · coeficientes ≠ causa
Matriz ★	linhas=real, colunas=previsto: TP FN FP TN · Acc=(TP+TN)/N · Rec=TP/(TP+FN) · Prec=TP/(TP+FP) · F1=2PR/(P+R) · **BalAcc**=média dos recalls · FP=erro I · FN=erro II
Cuidados ★	**accuracy alta engana** com grupos desequilibrados · recall alto ⇏ precision alta · **treino é otimista** → validação cruzada/teste · pressupostos: covariâncias iguais (**Box M**: p<0,05 evidência contra; p≥0,05 não prova igualdade), normalidade multivariada

Matriz [30 20 / 10 40] (positiva = com doença): TP, FN, FP, TN; accuracy, recall, precision? E [36 14 / 9 41]? TP30 FN20 FP10 TN40: acc 70/100=**0,70**; recall 30/50=**0,60**; prec 30/40=**0,75**; F1 0,667 · 2.ª: acc **77%**; recall 36/50=**72%**; prec 36/45=**80%**

D=−2,15+0,04·Idade+0,80·Satisf.+0,015·Despesa, cliente com 40, 7 e 80; corte 0. Grupo?
D=−2,15+1,6+5,6+1,2=**6,25**>0 → Grupo 1 · **[90 10 / 25 75]:** acc 165/200=**82,5%**; G1 90%; G2 75%

190 do grupo 1 e 10 do grupo 2; acertos 187 e 2: accuracy, taxa por grupo, balanced accuracy? acc 189/200=**94,5%**; G1 98,4%; **G2 20%**; BalAcc **59,2%** → a accuracy engana · **TP30 FN10 FP20 TN140:** recall **75%**, prec **60%**; para identificar quem abandona: **recall**

Accuracy treino 91,0% (BalAcc 88,5%) vs validação cruzada 82,5% (76,0%)? p=5 variáveis e K=3 grupos: nº de funções?
treino é otimista, CV mais realista · min(5,2)=**2**

*Guia para COPIAR À MÃO (o exame só permite uma folha A4 manuscrita). Fontes: slides, teste-modelo e solução, Modelo de Exame 2 e resolução, exercícios e soluções da UC. * = fora dos slides.*