FOLHA DE APOIO — frente (A a F, K)

★ = no teste-modelo/Modelo 2 · * = fora dos slides

A. Pergunta → o que fazer

procura rápida

Tipo de variável?	Quadro B
Que medida / teste?	Quadro D · casos no quadro E
Interprete r, p, V	Quadro F (frases prontas)
PCA: Kaiser, %, loading	Verso G · caso G1
ACS/ACM: inércia, cos²	Verso H · caso H1
Quantos clusters? silhouette	Verso I · caso I1
Matriz de confusão	Verso J · casos J1–J3
Verdadeiro/Falso	Quadro K (armadilhas, no fim desta página)
Que método?	Resumir quantitativas → **PCA** · associação entre categorias → **ACS/ACM** · descobrir grupos → **clustering** · classificar em grupos conhecidos → **discriminante**

B. Variáveis e estatística descritiva

★ T6, M2-1, M2-2

Se…	Tipo	Exemplos
categorias sem ordem	**nominal**	sexo, região, contrato, *código*
categorias com ordem	**ordinal**	satisfação b/m/a, escala 1–5, escolaridade, faixa etária
contagem (inteiros)	**discreta**	nº compras, reclamações, filhos
medição	**contínua**	€ gasto, idade, tempo

Média ou mediana?	Com extremos/assimetria → **mediana** (a média é puxada). 4,5,6,7,8,40: média 11,7; mediana 6,5
Quartis, AIQ	Q1/Q2/Q3 = 25/50/75% · AIQ=Q3−Q1 · **50% central entre Q1 e Q3**. Q1=1400, Q3=1800 → AIQ 400
Dispersão	amplitude=máx−mín · $s^2=\Sigma(x-\bar{x})^2/(n-1)$ · $s=\sqrt{s^2}$ · CV=s/$\bar{x}$
Forma	cauda à direita: média>mediana>moda · histograma = quantitativa em classes; barras/circular = qualitativa
Outlier / omisso	ver **origem** (erro de registo/medição ou caso real) e **impacto**. **Não eliminar automaticamente**; não substituir sempre pela média. Inconsistências: idade −3, duplicados, unidades
Número ≠ tipo	código 1/2/3 = nominal · escala 1–5 = ordinal · nº compras = discreta

C. Mais exemplos de tipo e descritiva

Norte/Centro/Sul → nominal · nível de risco 1–3 → ordinal · tempo de espera (min) → contínua · nº reclamações → discreta · método de pagamento → nominal
2,3,3,4,5,3,6 → moda 3; mediana 3; média 26/7≈3,71
Notas (média 5 nas duas): amplitude 4 vs 8; s^2 1,09 vs 8,54 → a 2.ª é mais dispersa
Intervalos de 5 min → **histograma** · omissos → origem e impacto antes de tratar

K. V/F — armadilhas

desconfia de "sempre", "causa", "prova"

F: associação ⇒ causa · r≈0 ⇒ sem relação · significativo ⇒ forte · padronizar elimina outliers · K-means escolhe k · silhouette máx. = grupos verdadeiros · ACS/ACM = clustering · proximidade ⇒ causa · 1.ª PC explica toda a variância · accuracy alta = bom em todos os grupos · 21% = prob. individual · **V:** loading = relação variável–componente · treino é otimista · inicializações diferentes → soluções diferentes

D. Bivariada: que medida?

★ M2-3, T2

X	Y	Medida	Caso
quant.	quant.	**Pearson**	salário×experiência; idade×rendimento
ordinal	ordinal	**Spearman**	★ satisfação 1–5 × recompra 1–5; rankings
quant.	binária	**ponto-bisserial**	satisfação×churn; rendimento×incumprimento
categ.	categ.	**χ^2 + V**	género×produto; canal×churn

r (Pearson)	−1≤r≤1 · sinal=direção · |r|=força · assume Normal · **r≈0 ⇏ sem relação** (só sem relação linear; pode ser U)
Spearman	usa ordens; associação monótona; robusta a outliers (horas de estudo×nota com extremos)
Ponto-bisserial	Pearson com 0/1; inverter 0/1 → |r| igual, **sinal troca**
χ^2 independência	H0 independentes · H1 associadas · observadas vs esperadas · `E=lin×col/n*` · `gl=(l−1)(c−1)*` · p<0,05 rejeita H0 · E adequadas (≥5*)
V de Cramér	0≤V≤1 · **χ^2 diz SE há; V diz QUANTO** · `V=√(χ²/(n·min(l−1,c−1)))*` · p<0,001 e V=0,08 → significativa mas **fraca**
Causalidade	X→Y? Y→X? **3.º fator**? acaso. Gelados×afogamentos (temperatura); guarda-chuvas×chocolate quente (frio)

E. Casos resolvidos — bivariada

E1 ★ M2-7	**[18 32 50 / 30 40 30]**, n=200. Totais colunas 48·72·80 → **E**=100·48/200=**24**; 36; 40 (ambas as linhas). $\chi^2=2\cdot(6^2/24+4^2/36+10^2/40)=2\cdot(1{,}5+0{,}44+2{,}5)=$**8,89**; gl=2; V=√(8,89/200)=**0,21**. p=0,002 (enunciado) → rejeita H0: há associação, **fraca a moderada**; sem causa
E2	**[80 20 / 60 40]** género×compra: E=70;30;70;30 → χ^2=9,52; gl=1; V=0,22
E3 ★ T8	**r=0,78**: positiva, forte; + publicidade ~ + vendas; **sem causa** (preço, sazonalidade, concorrência)
E4 ★ M2-8	**r=−0,64, p<0,001**: negativa, moderada a forte (+ espera, − satisfação); p = evidência contra r=0; não prova causa
E5	**r=0,03/0,01**: sem associação linear (≠ sem relação) · r_{pb}=−0,58 (churn=1): + satisfação ⇒ − churn · r=0,70 satisfação×retenção: "associadas" (≠ aumentar satisfação aumenta retenção)
E6	**Diretor:** "satisfação e retenção têm r=0,80, logo aumentemos a satisfação" → estão **associadas**; não prova causa (3.º fator, causa inversa); precisa de estudos adicionais
E7	Ranks satisfação 1..6 vs rentabilidade 2,1,4,3,5,6: monótona positiva forte (ρ≈0,89*)

F. Frases prontas de interpretação

r	"Associação linear [positiva/negativa] [fraca/moderada/forte] (r=…): quando X sobe, Y tende a […]. p<0,05: evidência contra r=0. Não implica causalidade."
χ^2+V	"p=… < 0,05 → rejeita-se H0: há evidência de associação. V=… → intensidade [fraca/moderada/forte]; relevância prática no contexto."
Escala dos modelos	|r|=0,78 forte · −0,64 moderada a forte · ≈0,02 nula · V=0,08 fraca · V=0,21 fraca a moderada

*Guia para COPIAR À MÃO (o exame só permite uma folha A4 manuscrita). Fontes: slides, teste-modelo e solução, Modelo de Exame 2 e resolução, exercícios e soluções da UC. * = fora dos slides.*

FOLHA DE APOIO — verso (G a J)

★ = no teste-modelo/Modelo 2 · * = fora dos slides

G. PCA / ACP — ★ T3, T9, M2-4, M2-9

O que é	Reduz a dimensionalidade preservando variância · PCs = **combinações lineares** ordenadas por variância · só **quantitativas** · nº máx = p · não prevê, não classifica, sem causalidade
Padronizar?	Sim se escalas diferentes: Z=(X−x̄)/s (preço 20–1000 dominaria)
Adequada?	**KMO** (0,76–0,84 = razoável/boa) + **Bartlett** H0: R=I, p<0,05 → há correlação (não diz quais; gl=p(p−1)/2*)
Quantas PCs?	**Kaiser λ>1** · scree (cotovelo) · % acumulada · interpretabilidade
% variância	λ/p* (Σλ=p*) · acumulada = soma
Loading / score	**loading** = variável↔componente (intensidade, sinal) · **score** = observação↔componente (posição)
Interpretar	mesmo sinal alto = fator **global** · sinais opostos = **contraste** · nome = interpretação · **scores próximos ⇏ semelhantes em tudo**
G1 ★ M2-9	λ=2,60; 0,82; 0,38; 0,20 (p=4). KMO 0,76 + Bartlett p<0,001 → **adequada**. Kaiser: só 2,60>1 → **1 componente**. C1=2,60/4=**65%**; C2=20,5%; acum. 85,5%. Loadings C1: qualidade 0,91; durab. 0,87; satisf. 0,89; preço −0,72 → contraste → **"valor/qualidade global percebida"**
G2	λ=3,18; 0,48; 0,25; 0,09 → C1=**79,5%**; C1+C2=**91,5%**; Kaiser 1 comp. · KMO 0,78, Bartlett χ^2=31,42, gl=6, p<0,001 → adequada · loadings 0,90–0,94 → "qualidade global do produto" · 1 comp. = simples/indicador único; 2 = mais informação
G3	Scores C1: máx. H (1,70), mín. A (−2,10) · score + ⇏ valores altos em todas as variáveis
G4 ★ T9	Cargas altas e + nas 4 → dimensão **global** de desempenho; limite: depende do significado das variáveis, sem fator causal. V/F: lin. comb. **V** · 1.ª PC explica sempre toda a variância **F** · reduz dimensionalidade **V**

H. ACS / ACM — ★ T10, M2-10

ACS / ACM	**ACS**: 2 categóricas (tabela de contingência) · **ACM**: várias (região, canal, plano, pagamento…); quantitativas só categorizadas · **não é clustering**, não segmenta
Inércia	(χ^2 diz **se** há associação, não **onde**) afastamento da independência (=χ^2/n*) · % dim = inércia dim/total · por representar = 100% − acumulada
Categoria	**coordenada** = posição · **contribuição** = peso na dimensão · **cos²** = qualidade de representação · **longe da origem ⇏ contribui muito**
Mapa	dimensão = contraste entre lados · proximidade ≠ associação direta/causal: ver contribuições, cos², % inércia
H1	Inércia total 0,109; D1=0,081 → **74,3%**; D1+D2=100% · ACM 38,6+24,7=**63,3%** → **36,7%** por representar
H2	Dim.1: Tecnologia (0,72; 31,5%) e 18–34 vs 50+ (−0,72) e Lazer (−0,51) → jovens/Tecnologia vs mais velhos/Lazer · Premium: cos² 0,91 = melhor representada
H3 ★ M2-10	Premium e Muito satisfeito próximos, cos² alto, Dim.1=62% → sugere associação. **Cautelas:** contribuições · **38% omitida** · sem causa · "ACM identificou segmentos" ✗ → clustering

I. Clustering — ★ T4, T11, M2-5/6/11

O que é	grupos **desconhecidos** (não supervisionado) · distâncias: euclidiana √Σ(p−q)² · Manhattan Σ|p−q| · Chebyshev máx|p−q| · matching (categ.) · Hamming (binárias) · padronizar: escala sim, **outliers não**
Hierárquico ★	aglomerativo: cada observação começa num cluster → agrega os mais próximos até 1 · dendrograma: altura = distância, corte → k (escolhido *depois*) · ligação: simples=mín · completa=máx · **Ward**=menor aumento de variância interna
K-means	k prévio → centros iniciais → atribuir ao mais próximo → recalcular → repetir · inicializações diferentes → soluções diferentes · numérico
Silhouette ★	s=(b−a)/máx(a,b): ≈1 bem integrada · ≈0 fronteira · <0 mal atribuída
Escolher k	silhouette máx. e tamanho do menor cluster + estabilidade + interpretabilidade; cotovelo (WSS)
Limites K-means ★	k prévio · inicialização · outliers/escala · clusters compactos de tamanho semelhante
I1 ★	**T11:** 0,44/**0,61**/0,52 → **K=3** · **M2-11:** 0,43/**0,57**/0,49 e menor cluster 38/18/**4%** → **K=3** (K=4 tem cluster de 4%) · grupos 120, 110 e 3 → não escolher automaticamente
I2	s(i): a=3, b=6 → (6−3)/6=**0,5** · a=5, b=2 → −0,6 · Ward 0,35/**0,41**/0,37/0,29 → 3 grupos
I3	p=(1,0,2), q=(6,0,3): Manhattan **6** · euclid. √26≈**5,10** · Chebyshev **5** · matching (V,P,G)/(A,P,E)=**2/3** · Hamming (1,0,1,1)/(1,1,0,1)=**2**
I4	Dendrograma de 8 obs.: início **8 grupos**; corte em 2 → {A,B,C,D},{E,F,G,H}
I5	Clusters 80/120/100, abandono 7,5/10/21%, p=0,012: variável **externa**; há associação; 21% ≠ risco individual; cluster×abandono ⇏ causa · "silhouette máx. ⇒ grupos verdadeiros" ✗

J. Discriminante — ★ T5, T12, M2-5, M2-12

O que é	grupos **conhecidos** (supervisionada): **classifica** em grupos definidos (≠ clustering; ≠ PCA) · $D=a_0+a_1X_1+\dots$ · D>corte → G1 · nº máx. funções **min(p,K−1)** · coeficientes ≠ causa
Pressupostos	normalidade multivariada · covariâncias iguais (**Box M**: p<0,05 = evidência contra; p≥0,05 não prova igualdade) · sem multicolinearidade grave
Matriz ★	linhas=real, colunas=previsto: TP FN FP TN · `Acc=(TP+TN)/N` · `Rec=TP/(TP+FN)` · `Prec=TP/(TP+FP)` · F1=2PR/(P+R) · **BalAcc**=média dos recalls · FP=erro I · FN=erro II
Cuidados ★	**accuracy alta engana** com grupos desequilibrados · recall alto ⇏ precision alta · **treino é otimista** → validação cruzada/teste
J1 ★	**T12** [30 20 / 10 40]: acc 70/100=**0,70** · recall 30/50=**0,60** · prec 30/40=**0,75** · F1=0,667 · **M2-12** [36 14 / 9 41]: **77%** · **72%** · **80%**
J2	D=−2,15+0,04·40+0,80·7+0,015·80=**6,25**>0 → G1 · [90 10 / 25 75]: acc 165/200=**82,5%**; G1 90%; G2 75%
J3	190 vs 10 (acertos 187 e 2): acc **94,5%**; G1 98,4%; **G2 20%**; BalAcc **59,2%** → accuracy engana · TP30 FN10 FP20 TN140: recall **75%**, prec **60%** → identificar quem abandona: **recall**
J4	Treino 91,0% (BalAcc 88,5%) vs CV 82,5% (76,0%): treino otimista · p=5,K=3 → **2** funções

*Guia para COPIAR À MÃO (o exame só permite uma folha A4 manuscrita). Fontes: slides, teste-modelo e solução, Modelo de Exame 2 e resolução, exercícios e soluções da UC. * = fora dos slides.*