Análise de Dados — FOLHA DE APOIO — frente

★ = no teste-modelo/Modelo 2 · * = fora dos slides · T = teste-modelo · M2 = Modelo 2

1. Análise preliminar

Pontos-chave

- ★ **Tipos: nominal** (sem ordem: sexo, região, código) · **ordinal** (ordem: satisfação b/m/a, escala 1–5, faixa etária) · **discreta** (contagem) · **contínua** (medição: €, idade, tempo). **Número ≠ quantitativa.** Linhas = unidades estatísticas; colunas = variáveis
- ★ **Média** sensível a extremos · **mediana** robusta (melhor com assimetria/outliers) · moda · cauda à direita: média>mediana>moda
- $s^2=\Sigma(x-\bar{x})^2/(n-1)$ · AIQ=Q3−Q1 · CV=s/$\bar{x}$ · 50% central entre Q1 e Q3 · histograma = quantitativa em classes; barras/circular = qualitativa
- ★ **Outlier** = muito afastado das restantes; **não eliminar automaticamente**: origem (erro de registo/medição ou caso real) + impacto. Omissos: identificar, origem, impacto (não substituir sempre pela média)

Exercícios

- nº compras = discreta · satisfação b/m/a = ordinal · € gasto = contínua · Norte/Centro/Sul = nominal · idade = contínua · "concordância" 1–5 = ordinal · código tipo cliente 1/2/3 = nominal
- 4,5,6,7,8,40 → média 11,7 > mediana 6,5 (a média é mais influenciada pelo 40) · Q1=1400, mediana=1600, Q3=1800 → AIQ=400; **50% entre 1400 e 1800** · tempos em intervalos de 5 min → histograma

2. Análise bivariada

Pontos-chave

- ★ **Medida:** quant×quant **Pearson** (linear) · ordinal×ordinal/rankings **Spearman** (robusta a outliers) · quant×binária **ponto-bisserial** (Pearson com 0/1; inverter 0/1: |r| igual, **sinal** troca) · categ×categ **χ^2+V**
- $-1\le r\le 1$: sinal = direção, |r| = força · ★ **r≈0 ⇏ sem relação** (só linear; pode ser U)
- ★ **χ^2:** H0 independentes · H1 associadas · compara observadas com esperadas · `E=lin×col/n*` · `gl=(l−1)(c−1)*` · p<0,05 rejeita H0 · E adequadas (≥5*). **V∈[0,1]** = intensidade: **χ^2 diz SE, V diz QUANTO** · $V=\sqrt{(\chi^2/(n\cdot\min(l-1,c-1)))}$* · p<0,001 e V=0,08 → significativa mas **fraca**
- ★ **Associação ≠ causalidade:** X→Y? Y→X? **3.º fator** (confundimento)? acaso. Gelados×afogamentos (temperatura); guarda-chuvas×chocolate quente (frio)

Exercícios

- ★ **r=0,78:** positiva, forte; sem causa (preço, sazonalidade, concorrência) · **r=−0,64, p<0,001:** negativa moderada-forte, p = evidência contra r=0 · **r=0,03/0,01:** sem associação *linear* · r_{pb}=−0,58 (churn=1): + satisfação ⇒ − churn
- salário×experiência Pearson · rankings Spearman · ★ satisfação 1–5×recompra 1–5 Spearman · rendimento×incumprimento ponto-bisserial · género×preferência, canal×churn χ^2+V · r=0,70/0,80 satisfação×retenção: "estão associadas" (≠ aumentar satisfação aumenta retenção)
- ★ **M2-7** [18 32 50 / 30 40 30]: E=24; 36; 40 (ambas as linhas) → $\chi^2=2\cdot(1{,}5+0{,}44+2{,}5)$=**8,89**, gl=2, V=**0,21**; p=0,002 (enunciado; cálculo ≈0,012) → rejeita H0, associação **fraca a moderada**, sem causa

3. ACP / PCA

Pontos-chave

- ★ Reduz a dimensionalidade preservando variância · PCs = **combinações lineares** ordenadas por variância · só **quantitativas** · nº máx = p · **padronizar** Z=(X−$\bar{x}$)/s (evita domínio pela escala, ex. preço 20–1000)
- **KMO** (0,76–0,84 = razoável/boa) · **Bartlett** H0: R=I (p<0,05 → há correlação; não diz quais; gl=p(p−1)/2*) · **Kaiser λ>1** · scree (cotovelo) · % acumulada · interpretabilidade · **%var=λ/p*** (Σλ=p*)
- ★ **Loading** = variável↔componente (intensidade e sinal) · **score** = observação↔componente (posição) · nome = interpretação (sintética)
- **Não**: causalidade · scores próximos ⇏ semelhantes em tudo · score + ⇏ valores altos em todas · perde informação

Exercícios

- ★ **M2-9:** λ=2,60; 0,82; 0,38; 0,20 (p=4): KMO 0,76 + Bartlett p<0,001 → adequada · Kaiser → **1** · C1=2,60/4=**65%** · C2=20,5% · acum. 85,5% · C1: qualidade 0,91; durab. 0,87; satisf. 0,89; preço −0,72 → contraste "valor/qualidade global percebida"
- **Exerc.:** λ=3,18; 0,48; 0,25; 0,09 → **79,5%** · 79,5+12,0=**91,5%** · Kaiser 1 comp. · KMO 0,78, Bartlett χ^2=31,42, gl=6, p<0,001 → adequada · loadings 0,90–0,94 → "qualidade global do produto" · score máx. H (1,70), mín. A (−2,10) · 1 comp. (simples, indicador único) vs 2 (mais informação)
- ★ **T9a:** cargas altas e + nas 4 → dimensão **global** de desempenho; limitação: depende do significado das variáveis e cargas, sem fator causal · V/F: lin. comb. **V** · 1.ª PC explica sempre toda a variância **F** · reduz dimensionalidade **V** · "qualidade causa satisfação" ✗ → "PCA identifica dimensão comum"

7. Escolher o método e como responder

- Pergunta → método: resumir quantitativas → **PCA** · associação entre categorias → **ACS/ACM** · descobrir grupos → **clustering** · classificar em grupos conhecidos → **discriminante**
- **Curta:** definição + exemplo/fórmula + 1 limite · **Longa:** tipo de variáveis → método → **cálculo com fórmula** → interpretar **no contexto** → limite (causalidade, extremos, representação)
- Escolha múltipla/V-F: desconfiar de "sempre", "necessariamente", "causa", "prova"

4. ACS / ACM

Pontos-chave

- ★ **ACS:** 2 categóricas (tabela de contingência) → mapa · **ACM:** várias categóricas (quantitativas — idade, rendimento, nº — só categorizadas e justificado). **Não é clustering**, não segmenta, sem causalidade
- χ^2 antes da ACS: diz **se** há associação global, não **onde** · ★ **Inércia** = afastamento da independência (=χ^2/n^*) · % dim = inércia dim/total · por representar = 100% − acumulada (ACM: inércia corrigida)
- ★ **Coordenada** = posição · **contribuição** = peso na construção da dimensão · **cos²** = qualidade de representação · **longe da origem ⇏ contribui muito/bem representada** · dimensão = contraste entre lados
- ★ Proximidade no mapa ≠ associação direta/causal: ver contribuições, cos², % de inércia, contexto

Exercícios

- Faixa etária = ordinal; produto = nominal (distinção relevante) · χ^2=28,64, gl=4, p<0,001 → rejeita H0; não identifica categorias; sem causa
- **Inércia** total 0,109; D1=0,081 → **74,3%**; D1+D2 → 100% (2 dim.) · ACM 38,6+24,7=**63,3%** → **36,7%** por representar
- Dim.1: Tecnologia (0,72; 31,5%) e 18–34 vs 50+ (−0,72) e Lazer (−0,51): jovens/Tecnologia vs mais velhos/Lazer · Casa contribui 35,4% na Dim.2 · ACM: lado +: 50+, Plano Premium (cos² 0,91, melhor representada), Compra Loja; lado −: 18–34, Básico, Online
- ★ **M2-10** (Premium e Muito satisfeito próximos, cos² alto, Dim.1=62%): sugere associação e boa representação; cautelas: **contribuições** · **38% omitida** · sem causa · "ACM identificou segmentos" ✗ (usar clustering) · "próximos ⇒ preferem" ✗

5. Análise classificatória (clustering)

Pontos-chave

- Grupos **desconhecidos** (não supervisionado) · homogéneo dentro, distinto entre · ★ distâncias: euclidiana $\sqrt{\Sigma(p-q)^2}$ · Manhattan $\Sigma|p-q|$ · Chebyshev máx$|p-q|$ · matching (categ.) · Hamming (binárias) · padronizar: escala sim, **outliers não**
- ★ **Hierárquico aglomerativo:** cada observação começa num cluster, agregam-se os mais próximos até 1 · dendrograma: altura = distância; corte → k (escolhido *depois*) · divisivo = inverso · ligação: **simples**=mín · **completa**=máx · **Ward**=menor aumento da variância interna
- **K-means** (não hierárquico, numérico, padronizado): k prévio → centros iniciais → atribuir ao mais próximo → recalcular → repetir · inicializações diferentes → soluções diferentes · não com nominais+euclidiana
- ★ **Silhouette** s=(b−a)/máx(a,b): ≈1 bem integrada · ≈0 fronteira · <0 mal atribuída · k: silhouette máx. e tamanho + estabilidade + interpretabilidade; cotovelo (WSS)
- ★ **Limitações K-means:** k prévio · inicialização · outliers/escala · clusters compactos de tamanho semelhante
- Caracterizar: médias + dispersão + tamanho · variável externa (abandono) ≠ causa · taxa do cluster ≠ prob. individual · métodos concordantes = evidência complementar · silhouette alto ⇏ "grupos verdadeiros"

Exercícios

- ★ **T11:** 0,44/**0,61**/0,52 → **K=3** · **M2-11:** 0,43/**0,57**/0,49, menor cluster 38/18/**4%** → **K=3** · grupos de 120, 110 e 3 obs. → não escolher automaticamente · Ward 0,35/**0,41**/0,37/0,29 → 3 grupos · K-means 0,36/**0,42**/0,35/0,29 → 3
- s(i): a=3, b=6 → (6−3)/6=**0,5** · a=5, b=2 → −0,6 · p=(1,0,2), q=(6,0,3): Manhattan **6** · euclid. $\sqrt{26}\approx$**5,10** · Chebyshev **5** · matching (V,P,G)/(A,P,E)=**2/3** · Hamming (1,0,1,1)/(1,1,0,1)=**2**
- Dendrograma de 8 obs.: início **8 grupos**; corte em 2 → {A,B,C,D} e {E,F,G,H} · A–B < A–C · clusters 80/120/100, abandono 7,5/10/21%, p=0,012: abandono é variável **externa**, há associação, 21% ≠ risco individual · híbrido 0,39 vs K-means 0,42 com tamanhos iguais: evidência complementar; estabilidade: inicializações, reamostragem

6. Análise discriminante

Pontos-chave

- ★ Grupos **conhecidos** (supervisionada): **classifica** em grupos previamente definidos (≠ clustering descobre; ≠ PCA reduz) · $D=a_0+a_1X_1+\ldots+a_pX_p$ · D>corte → G1 · nº máx. funções **min(p,K−1)** · coeficientes ≠ causa (ver escala e correlação entre variáveis)
- Pressupostos: normalidade multivariada · covariâncias iguais (**Box M**: p<0,05 = evidência contra; p≥0,05 não prova igualdade nem todos os pressupostos) · sem multicolinearidade grave · sem influentes
- ★ **Matriz** (linhas=real, colunas=previsto): TP FN FP TN · $Acc=(TP+TN)/N$ · $Rec=TP/(TP+FN)$ · $Prec=TP/(TP+FP)$ · F1=2PR/(P+R) · **BalAcc**=média das taxas corretas por grupo (recalls) · FP=erro I · FN=erro II
- ★ **Accuracy alta engana** com grupos desequilibrados → ver por grupo/BalAcc · recall alto ⇏ precision alta · ★ **treino é otimista** (mesmos dados) → validação cruzada/teste

Exercícios

- ★ **T12** [30 20 / 10 40]: acc **0,70** · recall **0,60** · prec **0,75** · F1 0,667 · **M2-12** [36 14 / 9 41]: **77%** · **72%** · **80%** · F1≈0,758
- **D**=−2,15+0,04·40+0,80·7+0,015·80=**6,25** > 0 → Grupo 1
- [90 10 / 25 75]: corretas 165/200 → acc **82,5%** · G1 90% · G2 75% · BalAcc 82,5%
- 190 vs 10 (acertos 187 e 2): acc **94,5%** · G1 98,4% · G2 **20%** · BalAcc **59,2%** → mau no G2, accuracy engana
- TP30 FN10 FP20 TN140: recall **75%** · prec **60%** · F1 0,667 · objetivo "identificar o máximo de quem abandona" → **recall**
- Treino 91,0% (BalAcc 88,5%) vs validação cruzada 82,5% (76,0%): treino otimista, CV mais realista; com desequilíbrio, BalAcc · accuracy 85% não basta: ver distribuição das classes, recall de Abandono, BalAcc, validação · p=5,K=3 → **2** funções