Análise de Dados — FOLHA DE APOIO — frente

★ = no teste-modelo/Modelo 2 · * = fora dos slides · T = teste-modelo · M2 = Modelo 2

1. Análise preliminar — pontos-chave

- ★ **Tipos: nominal** (sem ordem: sexo, região, código) · **ordinal** (ordem: satisfação b/m/a, escala 1–5, faixa etária, escolaridade) · **discreta** (contagem: nº compras, filhos) · **contínua** (medição: €, idade, tempo). **Número ≠ quantitativa.** Linhas = unidades estatísticas; colunas = variáveis
- ★ **Média** sensível a extremos · **mediana** robusta (melhor com assimetria/outliers) · moda (pode haver mais do que uma). Cauda à direita: média>mediana>moda; à esquerda: média<mediana<moda; simétrica: ≈
- **Dispersão:** amplitude=máx−mín (ignora valores intermédios) · $s^2=\Sigma(x-\bar{x})^2/(n-1)$ (usa todos) · $s=\sqrt{s^2}$ (mesma unidade) · AIQ=Q3−Q1 · CV=s/$\bar{x}$ · Q1/Q2/Q3 = 25/50/75% · **50% central entre Q1 e Q3**
- **Gráficos:** histograma = quantitativa em classes (barras contíguas; lê concentração, dispersão, assimetria) · barras/circular = qualitativa · boxplot = mediana, quartis, extremos
- ★ **Outlier** = muito afastado das restantes; **não eliminar automaticamente**: origem (erro de registo/medição ou caso real) + impacto
- **Omissos:** causas (não recolhido, resposta indisponível, erro de registo, não aplicável); quantos, onde, aleatórios? Não substituir sempre pela média. **Inconsistências:** valores impossíveis (idade −3, 250), categorias escritas de formas diferentes, unidades, duplicados

1b. Preliminar — exercícios

- nº compras = discreta · satisfação b/m/a = ordinal · € gasto = contínua · Norte/Centro/Sul = nominal · idade = contínua · "concordância" 1–5 = ordinal · código tipo cliente 1/2/3 = nominal · escolaridade (básico/secundário/superior) = ordinal · código postal = nominal
- 4,5,6,7,8,40 → média 70/6=11,7 > mediana (6+7)/2=6,5 → a média é mais influenciada pelo 40
- 2,3,3,4,5,3,6 → moda 3 · ordenados 2,3,3,3,4,5,6 → mediana 3 · média 26/7≈3,71
- 1200,1300,1400,1500,10000 → média 3080; mediana 1400
- Q1=1400, mediana=1600, Q3=1800 → AIQ=400 · **50% entre 1400 e 1800** · 3000 e 3500 = possíveis extremos
- Notas Biologia/Matemática (média 5 nas duas): amplitude 4 vs 8; s^2 1,09 vs 8,54 → Matemática mais dispersa
- Tempos em intervalos de 5 min → **histograma** · valores omissos → identificar, origem e impacto antes de tratar

2. Análise bivariada — pontos-chave

- ★ **Medida:** quant×quant **Pearson** (linear; assume Normal) · ordinal×ordinal/rankings **Spearman** (ranks, monótona, robusta a outliers) · quant×binária **ponto-bisserial** (Pearson com 0/1; inverter 0/1: |r| igual, **sinal** troca) · categ×categ **χ^2+V**
- −1≤r≤1: sinal = direção, |r| = força · ★ **r≈0 ⇏ sem relação** (só linear; pode ser U)
- ★ **χ^2:** H0 independentes · H1 associadas · observadas vs esperadas · `E=lin×col/n*` · `gl=(l−1)(c−1)*` · p<0,05 rejeita H0 · E adequadas (≥5*) · **V∈[0,1]** = intensidade · **χ^2 diz SE, V diz QUANTO** · `V=√(χ²/(n·min(l−1,c−1)))*`
- **p<0,001 e V=0,08** → significativa mas **fraca** (significância ≠ relevância prática)

2b. Bivariada — exercícios (interpretar r)

- ★ **r=0,78** publicidade×vendas: positiva, forte; sem causa (preço, sazonalidade, concorrência, mercado) · **r=−0,64, p<0,001**: negativa moderada-forte; p = evidência contra r=0 · **r=0,82** marketing/vendas: positiva forte · **r=−0,75** preço/quantidade: negativa forte · **r=0,03/0,01/0,02**: sem associação *linear* (≠ "sem relação")
- r_{pb}=−0,58 (churn=1): + satisfação ⇒ − churn · médias de satisfação: churn 3,5 vs não churn 8,5

2c. Bivariada — exercícios (medidas, χ^2, causalidade)

- salário×experiência, publicidade×vendas, visitas×gasto, idade×rendimento → **Pearson** · rankings (lojas, desempenho×satisfação) → **Spearman** · ★ satisfação 1–5×recompra 1–5 → **Spearman** · rendimento×incumprimento, satisfação×churn → **ponto-bisserial** · género×produto, género×churn, canal×churn, canal×plano → **χ^2+V** · horas de estudo×nota com outliers → Spearman
- 6 lojas: ranks satisfação 1,2,3,4,5,6 vs rentabilidade 2,1,4,3,5,6 → associação monótona positiva forte; ρ≈0,89*
- ★ **M2-7** [18 32 50 / 30 40 30]: E=24; 36; 40 (ambas as linhas) → $\chi^2=2\cdot(1{,}5+0{,}44+2{,}5)$=**8,89**, gl=2, V=**0,21**; p=0,002 (enunciado; cálculo ≈0,012) → rejeita H0, associação **fraca a moderada**, sem causa
- [80 20 / 60 40] (género×compra): E=70; 30; 70; 30 → χ^2=9,52; gl=1; V=0,22*
- ★ **Associação ≠ causalidade:** X→Y? Y→X? **3.º fator**? acaso. Gelados×afogamentos (temperatura); guarda-chuvas×chocolate quente (frio). r=0,70/0,80 satisfação×retenção → "estão associadas" (≠ aumentar a satisfação aumenta a retenção) · resposta ao diretor: associação ≠ causa; são precisos mais estudos

3. ACP / PCA — pontos-chave

- ★ Reduz a dimensionalidade preservando variância · PCs = **combinações lineares** ordenadas por variância · só **quantitativas** · nº máx = p · **padronizar** Z=(X−$\bar{x}$)/s (a escala não domina, ex. preço 20–1000)
- **Roteiro:** dados (tipos, extremos, escalas) → correlações, **KMO** (0,76–0,84 razoável/boa), **Bartlett** H0: R=I (p<0,05 → há correlação; não diz quais; gl=p(p−1)/2*) → nº de componentes: **Kaiser λ>1**, scree (cotovelo), % acumulada, interpretabilidade → loadings → nome → scores
- **%var=λ/p*** ($\Sigma\lambda$=p*) · ★ **loading** = variável↔componente (intensidade, sinal) · **score** = observação↔componente (posição) · nome = interpretação (sintética)
- Loadings altos e + em todas = fator **global**; sinais opostos = **contraste** · **Não**: causalidade · scores próximos ⇏ semelhantes em tudo · score + ⇏ valores altos em todas · perde informação

3b. PCA — exercícios

- ★ **M2-9:** λ=2,60; 0,82; 0,38; 0,20 (p=4): KMO 0,76 + Bartlett p<0,001 → adequada · Kaiser → **1** · C1=2,60/4=**65%** · C2=20,5% · acum. 85,5% · C1: qualidade 0,91; durab. 0,87; satisf. 0,89; preço −0,72 → "valor/qualidade global percebida"
- **Exerc.:** λ=3,18; 0,48; 0,25; 0,09 → **79,5%** · 79,5+12,0=**91,5%** · Kaiser 1 comp. · KMO 0,78, Bartlett χ^2=31,42, gl=6, p<0,001 → adequada · loadings 0,90–0,94 → "qualidade global do produto" · score máx. H (1,70), mín. A (−2,10) · 1 comp. (simples, indicador único) vs 2 (mais informação)
- **Slides (municípios):** λ=3,62; 1,74; 0,82; 0,61; 0,43; 0,32; 0,28; 0,18 (Σ=8) → Kaiser 2; 45,3+21,8=67,1% · C1 (rendimento 0,82; escolaridade 0,85; emprego 0,76) = "desenvolvimento socioeconómico"; C2 (transportes 0,78; internet 0,81; cultura 0,75) = "conectividade e participação" · KMO 0,84, Bartlett χ^2=842,6, gl=28
- **Exerc. 11:** "a PCA prova que a qualidade causa satisfação" ✗ · "C1 serve de indicador sintético" ✓ (com cautela) · "scores próximos ⇒ semelhantes em tudo" ✗ · "reduzir dimensão facilita a análise mas perde informação" ✓
- ★ **T9a:** cargas altas e + nas 4 → dimensão **global** de desempenho; limitação: depende do significado das variáveis e cargas, sem fator causal · V/F: lin. comb. **V** · 1.ª PC explica sempre toda a variância **F** · reduz dimensionalidade **V** · "qualidade causa satisfação" ✗ → "a PCA identifica uma dimensão comum"

Guia para COPIAR À MÃO (o exame só permite uma folha A4 manuscrita). Copia primeiro o que tem ★. Fontes: slides, teste-modelo e solução, Modelo de Exame 2 e resolução, exercícios e soluções da UC.

Análise de Dados — FOLHA DE APOIO — verso

★ = no teste-modelo/Modelo 2 · * = fora dos slides · T = teste-modelo · M2 = Modelo 2

7. Escolher o método e como responder

- Pergunta → método: resumir quantitativas → **PCA** · associação entre categorias → **ACS/ACM** · descobrir grupos → **clustering** · classificar em grupos conhecidos → **discriminante**
- **Curta:** definição + exemplo/fórmula + 1 limite · **Longa:** tipo de variáveis → método → **cálculo com fórmula** → interpretar **no contexto** → limite · V/F: desconfiar de "sempre", "necessariamente", "causa", "prova"

4. ACS / ACM — pontos-chave

- ★ **ACS:** 2 categóricas (tabela de contingência) → mapa · **ACM:** várias categóricas (região, sexo, canal, faixa etária, plano, pagamento); quantitativas (idade, rendimento, nº) só categorizadas e justificado · **não é clustering**, não segmenta, sem causalidade, sem previsão
- χ^2 antes da ACS: diz **se** há associação global, não **onde** (resíduos ajustados/mapa) · ★ **Inércia** = afastamento da independência (=χ^2/n^*) · % dim = inércia dim/total · por representar = 100% − acumulada (ACM: inércia corrigida)
- ★ **Coordenada** = posição · **contribuição** = peso na construção da dimensão · **cos²** = qualidade de representação · **longe da origem ⇏ contribui muito/bem representada** · dimensão = contraste entre lados
- ★ Proximidade no mapa ≠ associação direta/causal: ver contribuições, cos², % de inércia, contexto

4b. ACS / ACM — exercícios

- Faixa etária = ordinal; produto = nominal (distinção relevante) · χ^2=28,64, gl=4, p<0,001 → rejeita H0; não identifica categorias; sem causa · slides canal×produto (n=450): E(Loja,Alim.)=150·150/450=50 (obs. 80); E(Online,Tecn.)=180·160/450=64 (obs. 90)
- **Inércia** total 0,109; D1=0,081 → **74,3%**; D1+D2 → 100% (2 dim.) · ACM 38,6+24,7=**63,3%** → **36,7%** por representar · slides ACM: 57,3; 15,6; 13,8; 8,3 (acum. 72,9%)
- Dim.1: Tecnologia (0,72; 31,5%) e 18–34 (0,65) vs 50+ (−0,72) e Lazer (−0,51) → jovens/Tecnologia vs mais velhos/Lazer · Casa 35,4% na Dim.2 · slides: Online 0,72; 31,5%; cos² 0,82 vs Loja −0,18; 2,8%; 0,35
- ACM: lado +: 50+ (22,7%), Plano Premium (20,5%; cos² 0,91 = melhor representada), Compra Loja; lado −: 18–34, Básico, Online
- ★ **M2-10** (Premium e Muito satisfeito próximos, cos² alto, Dim.1=62%): sugere associação e boa representação; cautelas: **contribuições** · **38% omitida** · sem causa · "ACM identificou segmentos" ✗ (usar clustering) · "próximos ⇒ preferem" ✗

5. Análise classificatória — pontos-chave

- Grupos **desconhecidos** (não supervisionado) · homogéneo dentro, distinto entre · ★ distâncias: euclidiana $\sqrt{\Sigma(p-q)^2}$ · Manhattan $\Sigma|p-q|$ · Chebyshev máx$|p-q|$ (Minkowski r=1,2,∞) · matching (categ.) · Hamming (binárias) · padronizar (z ou min-max): escala sim, **outliers não** · nominais: one-hot
- ★ **Hierárquico aglomerativo:** cada observação começa num cluster, agregam-se os mais próximos até 1 · dendrograma: altura = distância; corte → k (escolhido *depois*) · divisivo = inverso · ligação: **simples**=mín · **completa**=máx · **Ward**=menor aumento da variância interna
- **K-means** (não hierárquico, numérico, padronizado): k prévio → centros iniciais → atribuir ao mais próximo → recalcular → repetir · inicializações diferentes → soluções diferentes · não com nominais+euclidiana
- Hierárquico vs K-means: hierarquia vs partição · k depois vs antes · dendrograma vs k grupos · progressivo vs iterativo

5b. Clustering — critérios e exercícios

- ★ **Silhouette** s=(b−a)/máx(a,b): ≈1 bem integrada · ≈0 fronteira · <0 mal atribuída · escolher k: silhouette máx. e tamanho + estabilidade + interpretabilidade + contexto; cotovelo (WSS) · ★ **limitações K-means:** k prévio · inicialização · outliers/escala · clusters compactos de tamanho semelhante
- Caracterizar: médias + dispersão + tamanho (slides: G1 idade 52, rendimento/despesa/satisfação altos; G2 31, médios; G3 45, baixos) · variável externa (abandono) ≠ causa · taxa do cluster ≠ prob. individual · métodos concordantes = evidência complementar · silhouette alto ⇏ "grupos verdadeiros"
- ★ **T11:** 0,44/**0,61**/0,52 → **K=3** · **M2-11:** 0,43/**0,57**/0,49, menor cluster 38/18/**4%** → **K=3** · grupos de 120, 110 e 3 obs. → não escolher automaticamente · Ward 0,35/**0,41**/0,37/0,29 → 3 grupos (simples 0,21→0,12) · K-means 0,36/**0,42**/0,35/0,29 → 3
- s(i): a=3, b=6 → (6−3)/6=**0,5** · a=5, b=2 → −0,6 · p=(1,0,2), q=(6,0,3): Manhattan **6** · euclid. √26≈**5,10** · Chebyshev **5** · matching (V,P,G)/(A,P,E)=**2/3** · Hamming (1,0,1,1)/(1,1,0,1)=**2**
- Dendrograma de 8 obs.: início **8 grupos**; corte em 2 → {A,B,C,D} e {E,F,G,H} · A–B < A–C (valores mais semelhantes) · ligação simples = menor distância entre duas observações
- Clusters 80/120/100, abandono 7,5/10/21%, p=0,012: abandono é variável **externa**, há associação, 21% ≠ risco individual · híbrido 0,39 vs K-means 0,42 com tamanhos iguais: evidência complementar; estabilidade: inicializações, reamostragem
- Analista: "silhouette máx. ⇒ grupos verdadeiros; cluster 3 ⇒ cada cliente 21%; associação ⇒ causa" → **F, F, F**; considerar estabilidade, tamanho e interpretabilidade → **V**

6. Análise discriminante — pontos-chave

- ★ Grupos **conhecidos** (supervisionada): **classifica** em grupos previamente definidos (≠ clustering descobre; ≠ PCA reduz) · $D=a_0+a_1X_1+\ldots+a_pX_p$ · D>corte → G1 · nº máx. funções **min(p,K−1)** · coeficientes ≠ causa (escala e correlação entre variáveis)
- Pressupostos: normalidade multivariada · covariâncias iguais (**Box M**: p<0,05 = evidência contra; p≥0,05 não prova igualdade nem todos os pressupostos) · sem multicolinearidade grave · sem influentes
- ★ **Matriz** (linhas=real, colunas=previsto): TP FN FP TN · $Acc=(TP+TN)/N$ · $Rec=TP/(TP+FN)$ · $Prec=TP/(TP+FP)$ · F1=2PR/(P+R) · **BalAcc**=média dos recalls · FP=erro I · FN=erro II
- ★ **Accuracy alta engana** com grupos desequilibrados → ver por grupo/BalAcc · recall alto ⇏ precision alta · ★ **treino é otimista** → validação cruzada/teste

6b. Discriminante — exercícios

- ★ **T12** [30 20 / 10 40]: acc **0,70** · recall **0,60** · prec **0,75** · F1 0,667 · **M2-12** [36 14 / 9 41]: **77%** · **72%** · **80%** · F1≈0,758 · slides [26 18 / 26 210]: acc 84,3% · recall 59,1% · prec 50% · F1 0,542
- **D**=−2,15+0,04·40+0,80·7+0,015·80=**6,25** > 0 → Grupo 1 · [90 10 / 25 75]: corretas 165/200 → acc **82,5%** · G1 90% · G2 75% · BalAcc 82,5%
- 190 vs 10 (acertos 187 e 2): acc **94,5%** · G1 98,4% · G2 **20%** · BalAcc **59,2%** → mau no G2 · TP30 FN10 FP20 TN140: recall **75%** · prec **60%** · F1 0,667 → para identificar quem abandona: **recall**
- Treino 91,0% (BalAcc 88,5%) vs CV 82,5% (76,0%): treino otimista · Box p=0,31: não rejeita H0, não prova igualdade · accuracy 85% não basta (classes, recall de Abandono, BalAcc, validação) · p=5,K=3 → **2** funções

Guia para COPIAR À MÃO (o exame só permite uma folha A4 manuscrita). Copia primeiro o que tem ★. Fontes: slides, teste-modelo e solução, Modelo de Exame 2 e resolução, exercícios e soluções da UC.