Análise de Dados — FOLHA DE APOIO — frente

T=teste-modelo · **M2**=Modelo 2 · *=fora dos slides

1. Tipos de variável T6 M2-1

Qualitativa	Quantitativa
Nominal (sem ordem): sexo, região, contrato, *código* **Ordinal** (com ordem): satisfação baixa/média/alta, escala 1–5, nível de risco, faixa etária	**Discreta** (contagem, inteiros): nº compras, filhos, reclamações **Contínua** (medição): € gasto, rendimento, idade, tempo

Número ≠ quantitativa (código = nominal). T6: nº compras = discreta · satisfação b/m/a = ordinal · € gasto = contínua · Norte/Centro/Sul = nominal.

2. Descritiva e qualidade dos dados T1 M2-2

- **Média** sensível a extremos · **mediana** (posição ordenada) **robusta** → melhor com assimetria ou outliers · moda = mais frequente. Ex.: 4,5,6,7,8,40 → média 11,7; mediana 6,5
- Amplitude=máx−mín · **$s^2=\Sigma(x-\bar{x})^2/(n-1)$** · $s=\sqrt{s^2}$ · **AIQ=Q3−Q1** · CV=s/$\bar{x}$
- Q1/Q2/Q3 = 25/50/75% · **50% central entre Q1 e Q3** · cauda à direita: média>mediana>moda
- **Outlier** [T1] = observação que se distingue significativamente das restantes. **Não se elimina sempre**: ver origem (erro de registo/medição ou caso real) e impacto
- Omissos: quantos, onde, porquê (não substituir sempre pela média) · inconsistências: valores impossíveis (idade −3), duplicados, unidades
- Gráficos: histograma = quantitativa em classes (barras contíguas) · barras/circular = qualitativa · boxplot = mediana, quartis, extremos

3. Que medida de associação? M2-3 T2

X	Y	Medida
quant.	quant.	**Pearson** (linear; assume Normal)
ordinal	ordinal	**Spearman** (ranks, monótona; robusta a outliers). M2-3: satisfação 1–5 × recompra 1–5 → Spearman
quant.	binária	**Ponto-bisserial** (Pearson com 0/1)
categ.	categ.	**χ^2 + V de Cramér**

Pearson: só **linear**, só quantitativas, **≠ causalidade**. Ponto-bisserial: inverter 0/1 muda o **sinal**, não |r|.

4. Interpretar um r T8 M2-8

- **Receita:** direção (sinal) + força (|r|) + significância (p) + **limite causal**
- T8: r=0,78 → associação linear **positiva e relativamente forte**: + publicidade tende a ir com + vendas
- M2-8: r=−0,64, p<0,001 → negativa moderada a forte (+ espera, − satisfação); p dá evidência contra correlação linear nula
- **Causa? NÃO.** Outros fatores (preço, sazonalidade, concorrência, mercado), causalidade inversa, 3.º fator (gelados×afogamentos: temperatura), acaso. Não exclui confundimento
- **r≈0 ⇏ sem relação**: só sem relação **linear** (pode ser U). r_{pb}=−0,58 (churn=1): + satisfação ⇒ − churn

5. χ^2 de independência e V de Cramér T7 T10 M2-7

- Tabela de contingência · H0: independentes · H1: associadas · $\chi^2=\Sigma(O-E)^2/E$ compara **observadas** com **esperadas sob independência**
- `E=tot.linha×tot.col/n*` · $gl=(l-1)(c-1)$* · p<0,05 → rejeita H0 (**há associação**) · válido se E adequadas (≥5*; senão Fisher*)
- **χ^2: HÁ associação? · V: QUÃO forte?** V∈[0,1], $V=\sqrt{(\chi^2/(n\cdot\min(l-1,c-1)))}$*
- M2-7: p=0,002 e V=0,21 → rejeita H0, há associação, **fraca a moderada**; relevância prática no contexto
- T10: significativo **⇏ forte** (p<0,001, V=0,08 → significativa mas fraca) · significativo = dados pouco compatíveis com independência, **≠ causa** (confundimento, outros mecanismos)
- χ^2 não diz *onde* está a associação (ACS / resíduos ajustados)
- Cálculo* M2-7 [18 32 50 / 30 40 30]: E=24,36,40 (2 linhas) → χ^2≈8,89, gl=2, V≈0,21

6. PCA T3 T9 M2-4 M2-9

- Só **quantitativas**; **padronizar** Z=(X−$\bar{x}$)/s · PCs = **combinações lineares**, ordenadas por variância; nº máx = p
- Objetivo: **reduzir dimensionalidade preservando a maior variância possível** (≠ classificar, ≠ causalidade, não prevê)
- Adequação: correlações · **KMO** (0,76 = razoável/boa) · **Bartlett** H0: R=I; p<0,05 rejeita ⇒ há correlação (gl=p(p−1)/2*)
- Reter: **Kaiser λ>1** · scree (cotovelo) · % acumulada · interpretabilidade
- **%var=λ/p** (Σλ=p). M2-9: λ=2,60/0,82/0,38/0,20 → só C1 (2,60>1); C1=2,60/4=**65%**
- **Loading** = variável↔componente (intensidade e sinal) · **Score** = observação↔componente (posição) [M2-4]
- **T9a:** cargas altas e + nas 4 variáveis → **dimensão global** de desempenho (valores altos nas 4 ⇒ score alto). **Limitação:** depende do significado das variáveis e das cargas; não prova fator causal comum; o nome é interpretação
- **M2-9d:** loadings +: qualidade, durabilidade, satisfação (0,91; 0,87; 0,89); −: preço percebido (−0,72) → "valor/qualidade global percebida" (dimensão sintética)
- **V/F T9b:** combinações lineares **V** · 1.ª PC explica sempre toda a variância **F** · reduz dimensionalidade **V** · scores próximos ⇏ semelhantes em tudo

Análise de Dados — FOLHA DE APOIO — verso

T=teste-modelo · **M2**=Modelo 2 · *=fora dos slides

7. ACS / ACM T10 M2-10

- ACS: 2 categóricas (tabela de contingência) → mapa · ACM: várias categóricas (quantitativas só categorizadas) · **não é clustering**, não dá causalidade nem segmentos
- **T10b V/F:** ACS representa graficamente as categorias **V** · proximidade no mapa ⇒ causalidade **F** · χ^2 significativo ⇒ associação forte **F**
- **Inércia** = afastamento da independência (=χ^2/n*). % dim = inércia dim/total · por representar = 100% − acumulada
- **Coordenada** = posição/sentido · **Contribuição** = peso na construção da dimensão · **cos²** = qualidade de representação. **Longe da origem ⇏ contribui muito nem bem representada**
- Dimensão = contraste entre categorias de sinais opostos
- **M2-10** (Premium e Muito satisfeito próximos, longe da origem, cos² alto, Dim.1=62%): sugere associação, boa representação. **2 cautelas:** (1) proximidade não basta sem **contribuições**; (2) plano omite **38%** da inércia; contexto, sem causalidade

8. Classificatória (clustering) T4 T11 M2-5 M2-6 M2-11

- Grupos **desconhecidos** · não supervisionado · homogéneo dentro, distinto entre. Distância euclidiana $\sqrt{\Sigma(p-q)^2}$; padronizar (resolve escala, **não outliers**)
- **T4 hierárquico aglomerativo:** cada observação começa num cluster e agregam-se sucessivamente os mais próximos até 1. Dendrograma: altura = distância, corte define k (escolhido *depois*). Ligação: simples=mín · completa=máx · Ward=menor aumento da variância interna
- **K-means:** k prévio → centros iniciais → atribuir ao mais próximo → recalcular → repetir. Numérico
- **Silhouette** s=(b−a)/max(a,b): **≈1** bem integrada e afastada dos outros · **≈0** fronteira · **negativo**: possivelmente mal atribuída (mais perto de outro cluster) [M2-6]
- **T11c:** K=2/3/4 → 0,44/**0,61**/0,52 → **K=3** (maior silhouette = melhor coesão e separação)
- **M2-11a:** 0,43/**0,57**/0,49, menor cluster 38%/18%/4% → **K=3**; K=4 pior e cluster de 4% pede cautela. Ver também tamanho, estabilidade, interpretabilidade
- **Limitações do K-means [T11d, M2-11b]:** k definido à partida · sensível à inicialização dos centroides · sensível a outliers/escala · favorece clusters compactos de forma/densidade semelhante
- Caracterizar com médias **e** dispersão e tamanho · taxa do cluster (21%) ≠ prob. individual · silhouette alto ⇏ "grupos verdadeiros"

9. Discriminante e classificação T5 T12 M2-5 M2-12

- Grupos **conhecidos** · supervisionada · **separa e classifica** em grupos previamente definidos · função $D=a_0+a_1X_1+\ldots$; nº máx. funções min(p,K−1)
- **M2-5:** clustering = grupos desconhecidos (não supervisionado) · discriminante = grupos conhecidos (supervisionado)
- **Matriz de confusão** (linhas=real, colunas=previsto): TP, FN, FP, TN
- `Acc=(TP+TN)/N` · `Recall=TP/(TP+FN)` · `Prec=TP/(TP+FP)` · F1=2PR/(P+R) · BalAcc=média dos recalls
- **T12** [30 20 / 10 40], positiva=Com doença: TP30 FN20 FP10 TN40 · acc=70/100=**0,70** · recall=30/50=**0,60** · prec=30/40=**0,75**
- **M2-12** [36 14 / 9 41], positiva=Em risco: TP36 FN14 FP9 TN41 · N=100 · acc=**77%** · recall=36/50=**72%** · prec=36/45=**80%** (F1≈0,758)
- **Avaliar no treino é otimista:** o modelo foi ajustado aos mesmos dados → teste independente ou validação cruzada
- Accuracy alta pode enganar com grupos desequilibrados → ver por grupo · FP = erro tipo I · FN = erro tipo II · coeficientes ≠ causa
- Pressupostos: normalidade multivariada, covariâncias iguais (Box, p<0,05 = evidência contra)

10. Escolha múltipla e V/F: respostas e armadilhas

- **T Grupo I:** 1=B (outlier: distingue-se das restantes) · 2=A (Pearson: linear, quantitativas) · 3=B (PCA: reduz dimensão) · 4=C (aglomerativo: cada observação começa num cluster) · 5=D (discriminante: classifica em grupos definidos)
- **Desconfiar** de: "sempre", "necessariamente", "causa", "qualquer tipo de variável", "toda a variância", "prova"
- F (exerc.): K-means escolhe k sozinho · padronizar elimina outliers · silhouette alto = grupos verdadeiros · ACM = clustering · accuracy alta = bom em todos os grupos
- V (exerc.): inicializações diferentes → soluções diferentes · discriminante é supervisionada

11. Como responder

- 1) tipo de variáveis → 2) método (pergunta→PCA/ACS-ACM/clustering/discriminante) → 3) **cálculo com fórmula** → 4) interpretar **no contexto** → 5) limite (causalidade, extremos, representação)
- Os modelos pedem: apresentar cálculos, justificar a escolha, interpretar no contexto; **associação ≠ causalidade**

12. Extras que podem sair (exercícios)

- **% inércia** = inércia da dimensão/total: 0,081/0,109=74,3%; ACM 38,6+24,7=63,3% → por representar 36,7%
- **Distâncias** p=(1,0,2), q=(6,0,3): Manhattan 6 · euclidiana $\sqrt{26}$ · Chebyshev 5. Ligação simples = menor distância entre duas observações
- **Dendrograma** de 8 observações: 8 grupos no início; cada etapa junta os 2 mais próximos; corte em 2 → {A,B,C,D} e {E,F,G,H}
- **PCA:** λ=3,18 → 79,5% (1 componente por Kaiser); 79,5+12,0=91,5% com 2; 1 PC = indicador único; 2 PC = mais informação
- **Cluster pequeno** (3 obs.) com o melhor silhouette: não escolher automaticamente

*Guia para COPIAR À MÃO (o exame só permite uma folha A4 manuscrita). Fontes: teste-modelo e solução, Modelo de Exame 2 e resolução, slides e exercícios da UC. * = fora dos slides.*