Análise de Dados — FOLHA DE APOIO — frente: notas

Curta=definir/indicar · **Longa**=interpretar · *=fora dos slides

1. Análise preliminar de dados

Curta

- **Tipos:** qualitativa **nominal** (sem ordem: sexo, região, código) · **ordinal** (ordem: satisfação b/m/a, escala 1–5, faixa etária) · quantitativa **discreta** (contagem) · **contínua** (medição). **Número ≠ quantitativa.**
- **Média** sensível a extremos · **mediana** robusta (posição ordenada) · moda. $s^2=\Sigma(x-\bar{x})^2/(n-1)$ · AIQ=Q3−Q1 · CV=s/$\bar{x}$ · 50% central entre Q1 e Q3 · cauda à direita: média>mediana>moda
- Histograma = quantitativa em classes (barras contíguas) · barras/circular = qualitativa · **outlier** = observação que se distingue muito das restantes

Longa

- **Outliers/omissos/inconsistências:** 1) detetar 2) perceber a origem (erro de registo/medição ou caso real) 3) avaliar o impacto 4) decidir e justificar. **Nunca eliminar automaticamente** nem substituir sempre pela média
- Checklist: unidade estatística · variáveis e tipos · distribuição · centro · dispersão · forma · omissos · extremos

2. Análise bivariada (associação)

Curta

- **Medida:** quant×quant **Pearson** (linear) · ordinal×ordinal **Spearman** (ranks, monótona, robusta a outliers) · quant×binária **ponto-bisserial** (Pearson com 0/1; inverter 0/1 muda só o **sinal**) · categ×categ **χ^2 + V de Cramér**
- $-1\le r\le 1$: sinal = direção; |r| = força. **r≈0 ⇏ sem relação** (só sem relação linear)
- **χ^2:** H0 independentes · $E=lin\times col/n^*$ · $gl=(l-1)(c-1)^*$ · p<0,05 rejeita H0 · E adequadas (≥5*). **V∈[0,1]** = força. **χ^2 diz SE há; V diz QUANTO**

Longa

- **Interpretar r:** direção + força + significância (p) + limite causal. **χ^2+V:** "há evidência de associação (p=…), de intensidade (V=…)"; p<0,001 e V=0,08 = significativa mas **fraca**
- **Causalidade:** X→Y? Y→X? **3.º fator** (confundimento) ou acaso. Gelados×afogamentos (temperatura); guarda-chuvas×chocolate quente. Ao "diretor": associação ≠ causa; são precisos estudos adicionais

3. ACP / PCA

Curta

- Reduz a dimensionalidade preservando variância · PCs = **combinações lineares** ordenadas por variância · só **quantitativas** · nº máx = p · **padronizar** Z=(X−$\bar{x}$)/s (a escala não domina)
- **KMO** (adequação) · **Bartlett** H0: R=I (p<0,05 → há correlação) · **Kaiser λ>1** · **%var=λ/p*** · **loading** = variável↔componente · **score** = observação↔componente

Longa

- **Roteiro:** dados (tipos, extremos, escalas) → adequação (correlações, KMO, Bartlett) → nº de componentes (Kaiser, scree, % acumulada, interpretabilidade) → loadings → nome → scores → limites
- **Interpretar:** loadings altos e + em todas = fator **global**; sinais opostos = **contraste**. Nome = interpretação, não variável observada
- **Limites:** sem causalidade · scores próximos ⇏ semelhantes em tudo · perde informação · 1 componente (simples) vs 2 (mais informação)

4. ACS / ACM

Curta

- **ACS:** 2 categóricas (tabela de contingência) → mapa · **ACM:** várias categóricas (quantitativas só categorizadas). **Não é clustering**, não segmenta, sem causalidade
- **Inércia** = afastamento da independência · % dim = inércia dim/total · por representar = 100% − acumulada · **coordenada** = posição · **contribuição** = peso na construção da dimensão · **cos²** = qualidade de representação · **longe da origem ⇏ contribui muito**

Longa

- **Roteiro:** categóricas → (ACS: χ^2 dá a associação global) → inércia e nº de dimensões → coordenadas (contraste entre lados) → contribuições → cos² → conclusão proporcional
- **Cautelas** com a proximidade no mapa: ver contribuições e cos² · % de inércia omitida · contexto · ≠ causa. ACM ≠ segmentos: para segmentar usar clustering

5. Análise classificatória (clustering)

Curta

- Grupos **desconhecidos** (não supervisionado) · homogéneo dentro, distinto entre. Distâncias: euclidiana, Manhattan, Chebyshev (quant.) · matching (categ.) · Hamming (binárias). Padronizar: escala sim, **outliers não**
- **Hierárquico aglomerativo:** n grupos → 1; dendrograma (altura = distância; corte → k). Ligação: simples=mín · completa=máx · Ward=menor aumento da variância interna. Divisivo = inverso
- **K-means:** k prévio → centros → atribuir → recalcular → repetir (numérico) · **silhouette** s=(b−a)/max(a,b): ≈1 bem integrada · ≈0 fronteira · <0 mal atribuída

Longa

- **Escolher k:** silhouette máxima e tamanho dos grupos (cluster de 3–4% = cautela) + estabilidade + interpretabilidade + contexto; cotovelo (WSS)
- **Caracterizar:** médias + dispersão + tamanho. Variável externa (abandono) ≠ causa; taxa do cluster (21%) ≠ prob. individual; métodos concordantes = evidência complementar, não prova de robustez
- **Limitações do K-means:** k prévio · inicialização · outliers/escala · clusters compactos de tamanho semelhante · só numéricas

6. Análise discriminante

Curta

- Grupos **conhecidos** (supervisionada) · $D=a_0+a_1X_1+\ldots+a_pX_p$ · nº máx. funções **min(p,K−1)** · pressupostos: normalidade multivariada, covariâncias iguais (**Box**: p<0,05 = evidência contra), sem multicolinearidade grave, sem influentes
- **Matriz** (linhas=real, colunas=previsto): TP, FN, FP, TN · $Acc=(TP+TN)/N$ · $Rec=TP/(TP+FN)$ · $Prec=TP/(TP+FP)$ · F1=2PR/(P+R) · BalAcc=média dos recalls · FP=erro I · FN=erro II

Longa

- **Avaliar:** matriz → accuracy → **por grupo** (recall, precision, F1) → grupos desequilibrados (acc 84%, recall G1 2%) → **validação fora da amostra** (treino é otimista; validação cruzada/teste) → pressupostos → coeficientes ≠ causa
- **Comparar:** PCA maximiza variância · discriminante maximiza separação · clustering descobre grupos

7. Como responder (curta vs longa)

- **Curta:** definição + exemplo/fórmula + 1 limite
- **Longa:** tipo de variáveis → método → **cálculo com fórmula** → interpretar **no contexto** → limite (causalidade, extremos, representação)
- Escolha múltipla / V-F: desconfiar de "sempre", "necessariamente", "causa", "prova"

Análise de Dados — FOLHA DE APOIO — verso: exercícios

T=teste-modelo · M2=Modelo 2 · *=fora dos slides

R1. Tipos de variável [T6] e escolha da medida [M2-3, ficha]

- nº compras → **discreta** · satisfação b/m/a → **ordinal** · € gasto → **contínua** · Norte/Centro/Sul → **nominal** · código postal → nominal · escala 1–5 → ordinal
- salário×experiência → **Pearson** · ranking×ranking; satisfação 1–5×recompra 1–5 → **Spearman** · rendimento×incumprimento (S/N); satisfação×churn → **ponto-bisserial** · género×preferência; canal×churn → **χ^2+V**

R2. χ^2 e V de Cramér [M2-7]: [18 32 50 / 30 40 30], n=200

- H0: canal e satisfação independentes · H1: associação
- Totais das colunas 48 · 72 · 80 → **E**=100×48/200=**24** · 100×72/200=**36** · 100×80/200=**40** (as duas linhas)
- χ^2=2×(6²/24 + 4²/36 + 10²/40)=2×(1,5+0,44+2,5)=**8,89** · gl=(2−1)(3−1)=**2**
- V=√(8,89/(200×1))=**0,21** (min(l−1,c−1)=1)
- p=0,002<0,05 (enunciado) → rejeita H0: **há associação**; V=0,21: **fraca a moderada**; relevância prática no contexto; sem causalidade. *(O cálculo dá p≈0,012 com gl=2: mesma conclusão.)*

R3. Interpretar r [T8, M2-8, ficha 3 e 7]

- **r=0,78** publicidade×vendas: positiva e forte; + publicidade ~ + vendas. **Não causal** (preço, sazonalidade, concorrência, mercado)
- **r=−0,64, p<0,001** espera×satisfação: negativa, moderada a forte (+ espera, − satisfação); p = evidência contra correlação linear nula; sem causalidade
- **r=0,02:** sem associação **linear**; não implica "sem relação" (pode ser U) · **r_{pb}=−0,58** (churn=1): + satisfação ⇒ − churn · inverter 0/1: |r| igual, sinal troca

R4. PCA [M2-9; exerc. 7]: λ=2,60; 0,82; 0,38; 0,20 (p=4)

- **Adequação:** KMO=0,76 razoável/boa; Bartlett p<0,001 → rejeita R=I → PCA adequada
- **Kaiser (λ>1):** só 2,60 → **1 componente**
- **%var:** C1=2,60/4=**65%** · C2=0,82/4=20,5% · acumulada C1+C2=**85,5%** (Σλ=p=4)
- **C1:** loadings qualidade 0,91 · durabilidade 0,87 · satisfação 0,89 · preço −0,72 → contraste: **"valor/qualidade global percebida"** (dimensão sintética)
- Exerc.: λ=3,18; 0,48; 0,25; 0,09 → C1=**79,5%**; C1+C2=**91,5%**; Kaiser → 1 componente (A: simples; B (2 comp.): mais informação)

R5. ACS / ACM com números [exerc. ACS_ACM; M2-10]

- Inércia total 0,109; D1=0,081; D2=0,028 → D1=0,081/0,109=**74,3%**; D1+D2=**100%** (2 dimensões)
- ACM: inércia corrigida 38,6% + 24,7% = **63,3%** → por representar 100−63,3 = **36,7%**
- Online: coord. 0,72 · contrib. 31,5% · cos² 0,82 → constrói a dimensão e está bem representada · Loja: −0,18 · 2,8% · 0,35 → pouco
- Dim.1: Tecnologia e 18–34 (+) vs Lazer e 50+ (−) → contraste mais jovens/Tecnologia vs mais velhos/Lazer
- M2-10: Premium e Muito satisfeito próximos, cos² alto, Dim.1=62% → sugere associação e boa representação. **Cautelas:** contribuições · 38% omitida · contexto · sem causa

R6. Clustering [T11, M2-11, exerc.]

- **T11:** silhouette 0,44 / **0,61** / 0,52 (K=2/3/4) → **K=3** (maior silhouette)
- **M2-11:** 0,43 / **0,57** / 0,49; menor cluster 38% / 18% / 4% → **K=3**; K=4 pior e cluster de 4%. Grupos de 120, 110 e 3 obs. → não escolher automaticamente
- s(i)=(b−a)/max(a,b): a=3, b=6 → (6−3)/6=**0,5** · a=5, b=2 → **−0,6** (mal atribuída)
- p=(1,0,2), q=(6,0,3): Manhattan=5+0+1=**6** · euclidiana=√26≈**5,10** · Chebyshev=**5**
- Matching (Verm.,Peq.,Gás)/(Azul,Peq.,Elétr.)=**2/3** · Hamming (1,0,1,1)/(1,1,0,1)=**2**
- Dendrograma de 8 obs.: início **8 grupos**; corte em 2 → {A,B,C,D} e {E,F,G,H}

R7. Matriz de confusão [T12, M2-12, slides]

- **T12** [30 20 / 10 40], positiva = Com doença: TP30 FN20 FP10 TN40 · N=100 · acc=70/100=**0,70** · recall=30/50=**0,60** · prec=30/40=**0,75** · F1=2·0,75·0,60/1,35=**0,667** · recall (sem doença)=40/50=0,80 · BalAcc=(0,60+0,80)/2=**0,70**
- **M2-12** [36 14 / 9 41], positiva = Em risco: TP36 FN14 FP9 TN41 · acc=77/100=**77%** · recall=36/50=**72%** · prec=36/45=**80%** · F1≈0,758
- **Slides** [26 18 / 26 210]: acc=236/280=**84,3%** · recall=26/44=59,1% · prec=26/52=50% · F1≈0,542
- Treino otimista: modelo ajustado aos mesmos dados → amostra de teste ou validação cruzada

R8. Discriminante e avaliação de conclusões

- nº funções = min(p,K−1): p=5,K=3 → **2** · p=4,K=5 → **4** · 2 grupos → **1** · D=2,1 e corte 0 → Grupo 1
- **Falsas:** silhouette máxima ⇒ "grupos verdadeiros" · 21% no cluster ⇒ prob. individual de cada cliente · cluster×abandono associados ⇒ causa · a ACM identificou segmentos prontos a usar (usar clustering) · proximidade no mapa ⇒ "preferem" · score + ⇒ valores altos em tudo · K-means escolhe k · K-means com nominais + euclidiana · accuracy alta ⇒ bom em todos os grupos · significativo ⇒ forte

R9. Modelo de resposta longa [M2-7]

- "H0: canal e satisfação são independentes; H1: há associação. Teste do **qui-quadrado** de independência. Como p=0,002<0,05, **rejeita-se H0**: há evidência de associação. V=0,21 → intensidade **fraca a moderada**; a relevância prática depende do contexto. Associação ≠ causalidade."

*Guia para COPIAR À MÃO (o exame só permite uma folha A4 manuscrita). Fontes: slides, teste-modelo e solução, Modelo de Exame 2 e resolução, exercícios da UC. * = fora dos slides.*