Análise de Dados — FOLHA DE APOIO (frente)

1. Tipos de variável

Qualitativa	Quantitativa
Nominal (sem ordem): sexo, região, tipo contrato, *código* cliente/postal **Ordinal** (com ordem): satisfação baixa/média/alta, escala 1–5, nível risco 1–3, faixa etária, escolaridade	**Discreta** (contagem): nº compras, filhos, reclamações **Contínua** (medição): rendimento, € gasto, idade, tempo (anos/min)

Os números NÃO definem o tipo (código 10234 = nominal). Quantitativas permitem operações aritméticas.

2. Estatística descritiva

- Média $\bar{x}=\Sigma x/n$ (sensível a extremos) · Mediana (valor central, robusta) · Moda (mais frequente)
- Amplitude = máx−mín · **$s^2=\Sigma(x-\bar{x})^2/(n-1)$** · $s=\sqrt{s^2}$ · **AIQ=Q3−Q1** · CV=s/$\bar{x}$ (×100%)
- Quartis: 25% abaixo de Q1, 50% abaixo da mediana, 75% abaixo de Q3; 50% central entre Q1 e Q3
- Cauda à direita: média>mediana>moda · à esquerda: média<mediana<moda · simétrica: ≈
- Histograma = quantitativa em classes (barras contíguas) · barras/circular = qualitativa · boxplot = mediana, quartis, extremos
- **Outlier: NÃO eliminar automaticamente** → ver origem (erro registo/medição/caso real) e impacto. Omissos: quantos? onde? aleatórios? (não substituir sempre pela média). Inconsistências: valores impossíveis (idade −3), duplicados, unidades
- Ex.: 4,5,6,7,8,40 → média 11,7 ≫ mediana 6,5

3. Medida de associação (X × Y)

X	Y	Medida
quant.	quant.	**Pearson** r (linear)
ordinal	ordinal	**Spearman** ρ (ranks, monótona; robusta a outliers)
quant.	binária	**Ponto-bisserial** (= Pearson c/ 0/1)
categ.	categ.	**χ^2 + V de Cramér**

- $-1\le r\le 1$: sinal = direção, |r| = força. **r≈0 ⇏ sem relação**: só sem relação **linear** (pode ser U). Pearson assume Normal.
- Ponto-bisserial: inverter a codificação 0/1 muda o **sinal**, não o |r|. $r_{pb}=-0{,}58$ (churn=1): + satisfação ⇒ − churn

4. Qui-quadrado e V de Cramér

- H0: independentes · H1: associadas · $\chi^2=\Sigma(O-E)^2/E$ · $E=tot.linha\times tot.col/n$ · $gl=(l-1)(c-1)$
- p<0,05 → rejeita H0 (há evidência de associação). Condição: E não muito pequenas (≥5), senão Fisher
- **χ^2 responde: HÁ associação? · V responde: QUÃO forte?** V∈[0,1]; $V=\sqrt{(\chi^2/(n\cdot\min(l-1,c-1)))}$
- **p<0,001 e V=0,08 → significativa mas FRACA** (significância ≠ relevância)
- χ^2 não diz *onde* está a associação (ACS / resíduos ajustados)
- Ex. 2×2 [80 20 / 60 40]: E=70,30,70,30 → χ^2=9,52 (gl=1), V=0,22

5. Associação ≠ causalidade

- X causa Y? · Y causa X? · **3.º fator (confundimento)**: gelados×afogamentos (temperatura); guarda-chuvas×chocolate quente (frio/chuva) · ou acaso
- Resposta-tipo: “X e Y estão associadas (r=…, direção, força); não se pode concluir causalidade porque …”

6. PCA / ACP

- Só **quantitativas**; **padronizar** $Z=(X-\bar{x})/s$ (escalas diferentes dominam) · PCs = **combinações lineares**, ordenadas por variância; nº máx = p
- Objetivo: **reduzir dimensionalidade preservando variância** (≠ classificar, ≠ causalidade)
- Adequação: correlações · **KMO** (0,76–0,84 = razoável/boa) · **Bartlett** H0: R=I; p<0,05 rejeita ⇒ há correlação (não diz quais; gl=p(p−1)/2)
- Reter: **Kaiser λ>1** · scree (cotovelo) · % acumulada · interpretabilidade (decisão conjunta)
- **%var da PC = λ/p** (Σλ=p). Ex.: λ=2,60; 0,82; 0,38; 0,20 → C1=65%, Kaiser: 1 PC
- **Loading** = variável↔componente (intensidade e sinal) · **Score** = observação↔componente (posição)
- Loadings altos e + em todas → fator *global* (ex.: “qualidade global”); sinais opostos → contraste (qualidade/durab./satisf. + vs preço −)
- **Nome = interpretação; scores próximos ⇏ semelhantes em tudo; sem causalidade; há perda de informação**

12. Notas dos modelos de exame (frente)

- **Tipos [Modelo]:** nº compras = discreta · satisfação baixo/médio/alto = ordinal · montante em € = contínua · Norte/Centro/Sul = nominal
- **Sexo × compra online [Modelo]:** tabela de contingência + χ^2 de Pearson (H0: independentes; H1: associadas), *desde que as frequências esperadas sejam adequadas*
- **r=0,78 publicidade×vendas [Modelo]:** associação linear positiva e relativamente forte. Causa? NÃO: outros fatores (preço, sazonalidade, concorrência, mercado)
- **PCA, C1 com cargas altas e + [Modelo]:** dimensão global de desempenho. Limitação: depende do significado das variáveis e das cargas; não prova fator causal comum. V/F: combinações lineares V · explica sempre toda a variância F · reduz dimensionalidade V
- **χ^2 [Modelo]:** compara frequências observadas com esperadas sob independência. V/F: significativo ⇒ forte F · ACS representa as categorias V · proximidade ⇒ causalidade F. Significativo = dados pouco compatíveis com independência, ≠ causa (confundimento, outros mecanismos)
- **Mediana vs média [Modelo 2]:** a mediana depende da posição ordenada, é robusta; melhor se assimétrica ou com outliers
- **Satisfação 1–5 × recompra 1–5 [Modelo 2]: Spearman** (duas ordinais, associação monótona)
- **χ^2 2×3 canal×satisf. [Modelo 2]:** p=0,002 → rejeita H0 (há associação); V=0,21 → fraca a moderada, relevância prática no contexto
- **r=−0,64 espera×satisf., p<0,001 [Modelo 2]:** negativa moderada a forte (+ espera, − satisfação); p dá evidência contra correlação linear nula; sem causalidade nem excluir confundimento
- **PCA 4 var., KMO=0,76, λ=2,60/0,82/0,38/0,20 [Modelo 2]:** KMO razoável/boa; Bartlett p<0,001 rejeita R=I; Kaiser → só C1 (2,60>1); var C1=2,60/4=**65%**; C1 opõe qualidade/durabilidade/satisfação a preço percebido → “valor/qualidade global percebida” (dimensão sintética)

Análise de Dados — FOLHA DE APOIO (verso)

7. Escolher o método (começar pela pergunta)

Resumir muitas var. quantitativas	**PCA**
Associação entre categorias	**ACS** (2 var.) · **ACM** (várias)
Descobrir grupos (desconhecidos)	**Classificatória** (não superv.)
Classificar em grupos conhecidos	**Discriminante** (superv.)

Maximizam: PCA→variância · Discriminante→separação entre grupos · Clustering→homogeneidade interna.

8. ACS / ACM

- ACS: tabela de contingência de 2 categóricas → mapa · ACM: várias categóricas (quantitativas só se categorizadas e justificado) · **não são clustering**, não dão causalidade nem segmentos (p/ segmentos: clustering)
- **Inércia** = afastamento da independência (= χ^2/n). %dim = inércia dim/inércia total. Ex.: 0,081/0,109 = 74,3%; não representada = 100% − acumulada (63,3% → 36,7% por representar)
- **Coordenada** = posição/sentido na dimensão · **Contribuição** (%) = peso na construção da dimensão · **cos²** = qualidade de representação
- **Longe da origem ⇏ contribui muito / bem representada.** Ler a dimensão como contraste entre categorias de sinais opostos (ex.: 18–34, Básico, Online vs 50+, Premium, Loja)
- **Proximidade ≠ associação direta/causal**: ver contribuições, cos², % de inércia (62% → 38% omitidos), contexto

9. Análise Classificatória

- Distâncias: Euclidiana $\sqrt{\Sigma(p-q)^2}$ · Manhattan $\Sigma|p-q|$ · Chebyshev $\max|p-q|$ · categóricas: matching (nº discordâncias/n) · binárias: Hamming. Ex. p=(1,0,2), q=(6,0,3): L1=6, L2=√26, L∞=5
- Padronizar (z / min-max): resolve a **escala**, **NÃO os outliers**
- **Hierárquico aglomerativo**: n grupos → junta os mais próximos → 1. **Dendrograma**: altura = distância; **corte** define k (k escolhido depois). Ligação: **simples**=distância mínima · **completa**=máxima · **Ward**=menor aumento da variabilidade interna. Divisivo = ao contrário
- **K-means** (não hierárquico, numérico): k prévio → centros iniciais → atribuir ao mais próximo → recalcular centros → repetir. Limitações: k prévio · inicialização/mínimo local · outliers · escala · clusters esféricos de tamanho semelhante · só numéricas
- **Silhouette** s=(b−a)/max(a,b): ≈1 bem integrada · ≈0 fronteira · <0 mal atribuída. Escolher k com silhouette média máxima mas ver tamanho (cluster de 3 obs / 4%), estabilidade, interpretabilidade. Cotovelo (WSS)
- Caracterizar: médias **e** dispersão e tamanho. Var. externa (abandono) ≠ causa; taxa do cluster (21%) ≠ prob. individual. Métodos concordantes = evidência complementar, não prova de robustez. Silhouette alto ⇏ "grupos verdadeiros"

10. Análise Discriminante

- Grupos **conhecidos** · $D=a_0+a_1X_1+\ldots+a_pX_p$ · D>corte→G1 · nº máx. funções **min(p,K−1)** (p=5,K=3 → 2)
- Pressupostos: normalidade multivariada nos grupos · covariâncias iguais (**Box** H0: $\Sigma_1=\ldots=\Sigma_K$; p<0,05 = evidência contra) · sem multicolinearidade grave · sem influentes
- **Matriz de confusão** (linhas=real, colunas=previsto): TP, FN, FP, TN
- `Acc=(TP+TN)/N · Recall=TP/(TP+FN) · Prec=TP/(TP+FP) F1=2·P·R/(P+R) · BalAcc=média dos recalls`
- FP = erro tipo I (falso alarme) · FN = erro tipo II (omissão)
- **Accuracy alta pode enganar** com grupos desequilibrados (acc 84%, recall G1 2%) → ver por grupo
- **Validar fora da amostra** (treino é otimista: validação cruzada / amostra de teste) · coeficientes ≠ causalidade
- Ex.: TP30 FN20 FP10 TN40 → acc 70%, rec 60%, prec 75%, F1 0,667 · TP36 FN14 FP9 TN41 → 77%, 72%, 80%

11. Como responder

- 1) tipo de variáveis → 2) método → 3) cálculo (mostrar a fórmula) → 4) interpretar **no contexto** → 5) limitação/causalidade
- Escolha múltipla: eliminar "causalidade", "sempre", "necessariamente"
- Justificar sempre (V/F: ler a palavra "sempre/toda/implica")

13. Notas dos modelos de exame (verso)

- **Mapa ACS: "Premium" e "Muito satisfeito" próximos, longe da origem, cos² alto, Dim.1=62% [Modelo 2]:** sugere associação e boa representação. Cautelas: proximidade visual não basta sem contribuições · o plano omite 38% da inércia · depende do contexto, sem causalidade
- **K-means, silhouette K=2/3/4 = 0,43/0,57/0,49, menor cluster 38%/18%/4% [Modelo 2]: K=3** (maior silhouette e menor cluster ainda 18%); K=4 pior e cluster de 4% pede cautela. Limitações: k prévio · inicialização dos centroides · escala/outliers · clusters compactos de forma semelhante
- **Silhouette K=2/3/4 = 0,44/0,61/0,52 [Modelo]: K=3** (maior silhouette = melhor coesão e separação). Limitação K-means: definir k à partida, inicialização, extremos, formas/densidades diferentes
- **Silhouette ≈1 / negativo [Modelo 2]:** bem integrada e afastada dos outros / pode estar mal atribuída (mais perto de outro cluster)
- **Clustering vs discriminante [Modelo 2]:** não supervisionado (grupos desconhecidos) vs supervisionado (grupos conhecidos; separar/classificar)
- **Matriz 30/20/10/40, positiva=Com doença [Modelo]:** TP30 FN20 FP10 TN40 · acc=70/100=**0,70** · recall=30/50=**0,60** · precision=30/40=**0,75**
- **Matriz 36/14/9/41, positiva=Em risco [Modelo 2]:** TP36 FN14 FP9 TN41 · N=100 · acc=**77%** · recall=36/50=**72%** · precision=36/45=**80%** · F1≈0,758
- **Avaliar no treino é otimista [Modelo 2]:** o modelo foi ajustado aos mesmos dados → usar teste independente ou validação cruzada
- **Instrução dos modelos:** mostrar cálculos, justificar a escolha do método, interpretar no contexto; associação ≠ causalidade

Folha-guia para COPIAR À MÃO (o exame só permite A4 manuscrita). Fontes: slides da UC, exercícios e modelos de exame.