Análise de Dados — Teste de treino

Duração: 60 minutos · Cotação: 20 valores · Formato do teste-modelo, com o quadro correspondente da folha de apoio ao lado de cada questão

Nome: _____	Hora de início: _____

Como usar: resolve cada questão consultando só o quadro ao lado (é o conteúdo da tua folha de apoio). Apresenta cálculos, justifica e interpreta no contexto. A resolução está no fim deste PDF (a partir da página 7): só a consultes depois de terminares.

Grupo I — Questões de escolha múltipla (cada questão: 0,8 valores; selecione uma única resposta)

Questão 1. Numa distribuição assimétrica com cauda longa à direita, a relação habitual entre as medidas de tendência central é: 0,8 val.

a) média < mediana < moda.
b) média = mediana = moda.
c) média > mediana > moda.
d) mediana > média > moda.

QUADRO DA FOLHA DE APOIO — CAIXA 2

2. Descritiva e qualidade dos dados T1 M2-2

- **Média** sensível a extremos · **mediana** (posição ordenada) **robusta** → melhor com assimetria ou outliers · moda = mais frequente. Ex.: 4,5,6,7,8,40 → média 11,7; mediana 6,5
- Amplitude=máx−mín · $s^2=\Sigma(x-\bar{x})^2/(n-1)$ · $s=\sqrt{s^2}$ · **AIQ=Q3−Q1** · CV=s/x̄
- Q1/Q2/Q3 = 25/50/75% · **50% central entre Q1 e Q3** · cauda à direita: média>mediana>moda
- **Outlier** [T1] = observação que se distingue significativamente das restantes. **Não se elimina sempre**: ver origem (erro de registo/medição ou caso real) e impacto
- Omissos: quantos, onde, porquê (não substituir sempre pela média) · inconsistências: valores impossíveis (idade −3), duplicados, unidades
- Gráficos: histograma = quantitativa em classes (barras contíguas) · barras/circular = qualitativa · boxplot = mediana, quartis, extremos

Questão 2. O coeficiente de correlação de Spearman é a medida mais adequada para avaliar a associação entre: 0,8 val.

a) duas variáveis nominais.
b) duas variáveis ordinais, por exemplo o ranking de satisfação e o ranking de preço.
c) uma variável quantitativa e uma variável binária.
d) duas variáveis categóricas com três ou mais categorias.

QUADRO DA FOLHA DE APOIO — CAIXA 3

3. Que medida de associação? M2-3 T2

X	Y	Medida
quant.	quant.	**Pearson** (linear; assume Normal)
ordinal	ordinal	**Spearman** (ranks, monótona; robusta a outliers). M2-3: satisfação 1–5 × recompra 1–5 → Spearman
quant.	binária	**Ponto-bisserial** (Pearson com 0/1)
categ.	categ.	**χ^2 + V de Cramér**

Pearson: só **linear**, só quantitativas, **≠ causalidade**. Ponto-bisserial: inverter 0/1 muda o **sinal**, não |r|.

Questão 3. Numa PCA, um loading elevado e positivo de uma variável numa componente indica que: 0,8 val.

a) a observação ocupa uma posição elevada nessa componente.

b) a variável tem uma relação forte e positiva com essa componente.

c) a variável causa a componente.

d) a componente explica toda a variância dos dados.

QUADRO DA FOLHA DE APOIO — CAIXA 6

6. PCA T3 T9 M2-4 M2-9

- Só **quantitativas**; **padronizar** $Z=(X-\bar{x})/s$ · PCs = **combinações lineares**, ordenadas por variância; nº máx = p
- Objetivo: **reduzir dimensionalidade preservando a maior variância possível** (≠ classificar, ≠ causalidade, não prevê)
- Adequação: correlações · **KMO** (0,76 = razoável/boa) · **Bartlett** H0: R=I; p<0,05 rejeita ⇒ há correlação ($gl=p(p-1)/2$*)
- Reter: **Kaiser λ>1** · scree (cotovelo) · % acumulada · interpretabilidade
- **%var=λ/p** ($\Sigma\lambda=p$). M2-9: λ=2,60/0,82/0,38/0,20 → só C1 (2,60>1); C1=2,60/4=**65%**
- **Loading** = variável↔componente (intensidade e sinal) · **Score** = observação↔componente (posição) [M2-4]
- **T9a:** cargas altas e + nas 4 variáveis → **dimensão global** de desempenho (valores altos nas 4 ⇒ score alto). **Limitação:** depende do significado das variáveis e das cargas; não prova fator causal comum; o nome é interpretação
- **M2-9d:** loadings +: qualidade, durabilidade, satisfação (0,91; 0,87; 0,89); −: preço percebido (−0,72) → "valor/qualidade global percebida" (dimensão sintética)
- **V/F T9b:** combinações lineares **V** · 1.ª PC explica sempre toda a variância **F** · reduz dimensionalidade **V** · scores próximos ⇏ semelhantes em tudo

Questão 4. Relativamente ao método K-means, é correto afirmar que: 0,8 val.

a) o número de clusters é determinado automaticamente pelo algoritmo.

b) o resultado pode depender da inicialização dos centros.

c) pode ser aplicado diretamente, com distância euclidiana, a variáveis nominais.

d) produz como resultado um dendrograma.

QUADRO DA FOLHA DE APOIO — CAIXA 8

8. Classificatória (clustering) T4 T11 M2-5 M2-6 M2-11

- Grupos **desconhecidos** · não supervisionado · homogéneo dentro, distinto entre. Distância euclidiana $\sqrt{\Sigma(p-q)^2}$; padronizar (resolve escala, **não outliers**)
- **T4 hierárquico aglomerativo:** cada observação começa num cluster e agregam-se sucessivamente os mais próximos até 1. Dendrograma: altura = distância, corte define k (escolhido *depois*). Ligação: simples=mín · completa=máx · Ward=menor aumento da variância interna
- **K-means:** k prévio → centros iniciais → atribuir ao mais próximo → recalcular → repetir. Numérico
- **Silhouette** s=(b−a)/max(a,b): **≈1** bem integrada e afastada dos outros · **≈0** fronteira · **negativo**: possivelmente mal atribuída (mais perto de outro cluster) [M2-6]
- **T11c:** K=2/3/4 → 0,44/**0,61**/0,52 → **K=3** (maior silhouette = melhor coesão e separação)
- **M2-11a:** 0,43/**0,57**/0,49, menor cluster 38%/18%/4% → **K=3**; K=4 pior e cluster de 4% pede cautela. Ver também tamanho, estabilidade, interpretabilidade
- **Limitações do K-means [T11d, M2-11b]:** k definido à partida · sensível à inicialização dos centroides · sensível a outliers/escala · favorece clusters compactos de forma/densidade semelhante
- Caracterizar com médias **e** dispersão e tamanho · taxa do cluster (21%) ≠ prob. individual · silhouette alto ⇏ "grupos verdadeiros"

Questão 5. O recall (sensibilidade) de uma classe é dado por: 0,8 val.

a) TP / (TP + FP).

b) (TP + TN) / N.

c) TP / (TP + FN).

d) TN / (TN + FP).

QUADRO DA FOLHA DE APOIO — CAIXA 9

9. Discriminante e classificação T5 T12 M2-5 M2-12

- Grupos **conhecidos** · supervisionada · **separa e classifica** em grupos previamente definidos · função $D=a_0+a_1X_1+\ldots$; nº máx. funções min(p,K−1)
- **M2-5:** clustering = grupos desconhecidos (não supervisionado) · discriminante = grupos conhecidos (supervisionado)
- **Matriz de confusão** (linhas=real, colunas=previsto): TP, FN, FP, TN
- `Acc=(TP+TN)/N` · `Recall=TP/(TP+FN)` · `Prec=TP/(TP+FP)` · F1=2PR/(P+R) · BalAcc=média dos recalls
- **T12** [30 20 / 10 40], positiva=Com doença: TP30 FN20 FP10 TN40 · acc=70/100=**0,70** · recall=30/50=**0,60** · prec=30/40=**0,75**
- **M2-12** [36 14 / 9 41], positiva=Em risco: TP36 FN14 FP9 TN41 · N=100 · acc=**77%** · recall=36/50=**72%** · prec=36/45=**80%** (F1≈0,758)
- **Avaliar no treino é otimista:** o modelo foi ajustado aos mesmos dados → teste independente ou validação cruzada
- Accuracy alta pode enganar com grupos desequilibrados → ver por grupo · FP = erro tipo I · FN = erro tipo II · coeficientes ≠ causa
- Pressupostos: normalidade multivariada, covariâncias iguais (Box, p<0,05 = evidência contra)

Grupo II — Questões de resposta aberta

Questão 6. Classifique cada uma das seguintes variáveis quanto à sua natureza, indicando o tipo de variável mais adequado. *(0,5 val. cada)* 2,0 val.

a) Número de reclamações apresentadas por um cliente.

b) Nível de escolaridade: básico, secundário ou superior.

c) Tempo de espera, em minutos.

d) Método de pagamento: crédito, débito ou transferência.

QUADRO DA FOLHA DE APOIO — CAIXA 1

1. Tipos de variável T6 M2-1

Qualitativa	Quantitativa
Nominal (sem ordem): sexo, região, contrato, *código* **Ordinal** (com ordem): satisfação baixa/média/alta, escala 1–5, nível de risco, faixa etária	**Discreta** (contagem, inteiros): nº compras, filhos, reclamações **Contínua** (medição): € gasto, rendimento, idade, tempo

Número ≠ quantitativa (código = nominal). T6: nº compras = discreta · satisfação b/m/a = ordinal · € gasto = contínua · Norte/Centro/Sul = nominal.

Questão 7. Pretende-se avaliar se o grupo etário de um cliente está associado à subscrição de um serviço premium. Obteve-se: 2,5 val.

	Subscreve	Não subscreve	Total
Jovem	45	55	100
Adulto	30	70	100
Total	75	125	200

a) Indique o tipo de teste adequado e formule H_0 e H_1. *(0,5)*

b) Calcule a frequência esperada da célula Jovem/Subscreve e diga se a condição de aplicação do teste parece satisfeita. *(0,5)*

c) Foi obtido p = 0,03 e V de Cramér = 0,15. Interprete os resultados. *(1,0)*

d) Pode concluir-se que ser jovem leva à subscrição? Justifique. *(0,5)*

QUADRO DA FOLHA DE APOIO — CAIXA 5

5. χ^2 de independência e V de Cramér T7 T10 M2-7

- Tabela de contingência · H0: independentes · H1: associadas · $\chi^2=\Sigma(O-E)^2/E$ compara **observadas** com **esperadas sob independência**
- `E=tot.linha×tot.col/n*` · `gl=(l−1)(c−1)*` · p<0,05 → rejeita H0 (**há associação**) · válido se E adequadas (≥5*; senão Fisher*)
- **χ^2: HÁ associação? · V: QUÃO forte?** V∈[0,1], $V=\sqrt{(\chi^2/(n\cdot\min(l-1,c-1)))}$*
- M2-7: p=0,002 e V=0,21 → rejeita H0, há associação, **fraca a moderada**; relevância prática no contexto
- T10: significativo ⇏ **forte** (p<0,001, V=0,08 → significativa mas fraca) · significativo = dados pouco compatíveis com independência, **≠ causa** (confundimento, outros mecanismos)
- χ^2 não diz *onde* está a associação (ACS / resíduos ajustados)
- Cálculo* M2-7 [18 32 50 / 30 40 30]: E=24,36,40 (2 linhas) → χ^2≈8,89, gl=2, V≈0,21

Questão 8.

2,0 val.

a) O coeficiente de correlação de Pearson entre as horas de formação e a produtividade dos trabalhadores é r = 0,71, com p < 0,001. Interprete direção, intensidade e significância. *(1,0)*

b) É possível concluir que a formação aumenta a produtividade? Justifique. *(0,5)*

c) Entre duas outras variáveis obteve-se r = 0,02. Pode concluir-se que não existe qualquer relação entre elas? Justifique. *(0,5)*

QUADRO DA FOLHA DE APOIO — CAIXA 4

4. Interpretar um r T8 M2-8

- **Receita:** direção (sinal) + força (|r|) + significância (p) + **limite causal**
- T8: r=0,78 → associação linear **positiva e relativamente forte**: + publicidade tende a ir com + vendas
- M2-8: r=−0,64, p<0,001 → negativa moderada a forte (+ espera, − satisfação); p dá evidência contra correlação linear nula
- **Causa? NÃO.** Outros fatores (preço, sazonalidade, concorrência, mercado), causalidade inversa, 3.º fator (gelados×afogamentos: temperatura), acaso. Não exclui confundimento
- **r≈0 ⇏ sem relação**: só sem relação **linear** (pode ser U). r_{pb}=−0,58 (churn=1): + satisfação ⇒ − churn

Questão 9.

3,0 val.

Foi aplicada uma PCA a cinco indicadores quantitativos, padronizados, de vários concelhos. KMO = 0,81 e teste de Bartlett com p < 0,001. Os valores próprios são 2,90; 1,30; 0,40; 0,25 e 0,15. Os loadings das duas primeiras componentes são:

Indicador	C1	C2
Rendimento médio	0,93	0,10
Escolaridade média	0,91	0,05
Taxa de emprego	0,89	0,07
Acesso à internet	0,45	0,80
Participação cultural	0,46	0,80

a) Avalie a adequação da PCA. *(0,5)*

b) Pelo critério de Kaiser, quantas componentes reteria? *(0,5)*

c) Calcule a variância explicada por C1 e a variância acumulada explicada por C1 e C2. *(1,0)*

d) Proponha uma interpretação para C1 e para C2. *(1,0)*

QUADRO DA FOLHA DE APOIO — CAIXA 6

6. PCA T3 T9 M2-4 M2-9

- Só **quantitativas**; **padronizar** Z=(X−x̄)/s · PCs = **combinações lineares**, ordenadas por variância; nº máx = p
- Objetivo: **reduzir dimensionalidade preservando a maior variância possível** (≠ classificar, ≠ causalidade, não prevê)
- Adequação: correlações · **KMO** (0,76 = razoável/boa) · **Bartlett** H0: R=I; p<0,05 rejeita ⇒ há correlação (gl=p(p−1)/2*)
- Reter: **Kaiser λ>1** · scree (cotovelo) · % acumulada · interpretabilidade
- **%var=λ/p** (Σλ=p). M2-9: λ=2,60/0,82/0,38/0,20 → só C1 (2,60>1); C1=2,60/4=**65%**
- **Loading** = variável↔componente (intensidade e sinal) · **Score** = observação↔componente (posição) [M2-4]
- **T9a:** cargas altas e + nas 4 variáveis → **dimensão global** de desempenho (valores altos nas 4 ⇒ score alto). **Limitação:** depende do significado das variáveis e das cargas; não prova fator causal comum; o nome é interpretação
- **M2-9d:** loadings +: qualidade, durabilidade, satisfação (0,91; 0,87; 0,89); −: preço percebido (−0,72) → "valor/qualidade global percebida" (dimensão sintética)
- **V/F T9b:** combinações lineares **V** · 1.ª PC explica sempre toda a variância **F** · reduz dimensionalidade **V** · scores próximos ⇏ semelhantes em tudo

Questão 10. Fez-se uma ACS à tabela canal de compra × faixa etária. A inércia total é 0,200; a dimensão 1 tem inércia 0,150, a dimensão 2 tem 0,040 e a dimensão 3 tem 0,010. Para a dimensão 1: 2,0 val.

Categoria	Coordenada	Contribuição (%)	cos²
Online	0,70	50,0	0,85
Loja	−0,40	20,0	0,45
Misto	−0,50	30,0	0,60
18–34	0,65	45,0	0,80
35–49	−0,10	15,0	0,05
50+	−0,72	40,0	0,90

a) Calcule a % de inércia explicada pela dimensão 1, a acumulada pelas duas primeiras dimensões e a % que fica por representar num mapa bidimensional. *(0,75)*

b) Que categoria mais contribui para a dimensão 1? Que categoria tem a coordenada de maior valor absoluto? São a mesma? Que categoria está melhor representada? *(0,75)*

c) Indique V ou F: i) uma coordenada elevada implica sempre uma contribuição elevada; ii) a ACS e a ACM são métodos de clustering; iii) o cos² mede a qualidade de representação de uma categoria numa dimensão. *(0,5)*

QUADRO DA FOLHA DE APOIO — CAIXA 7

7. ACS / ACM T10 M2-10

- ACS: 2 categóricas (tabela de contingência) → mapa · ACM: várias categóricas (quantitativas só categorizadas) · **não é clustering**, não dá causalidade nem segmentos
- **T10b V/F:** ACS representa graficamente as categorias **V** · proximidade no mapa ⇒ causalidade **F** · χ^2 significativo ⇒ associação forte **F**
- **Inércia** = afastamento da independência (=χ^2/n^*). % dim = inércia dim/total · por representar = 100% − acumulada
- **Coordenada** = posição/sentido · **Contribuição** = peso na construção da dimensão · **cos²** = qualidade de representação. **Longe da origem ⇏ contribui muito nem bem representada**
- Dimensão = contraste entre categorias de sinais opostos
- **M2-10** (Premium e Muito satisfeito próximos, longe da origem, cos² alto, Dim.1=62%): sugere associação, boa representação. **2 cautelas:** (1) proximidade não basta sem **contribuições**; (2) plano omite **38%** da inércia; contexto, sem causalidade

Questão 11. Foram comparadas soluções de K-means para segmentar clientes: 2,0 val.

K	Silhouette média	Menor cluster
2	0,38	40%
3	0,47	22%
4	0,52	3%
5	0,40	2%

a) Que solução escolheria? Discuta se K = 4 deve ser escolhido automaticamente. *(1,0)*

b) Uma observação tem distância média ao seu cluster a(i) = 3 e distância média ao cluster alternativo mais próximo b(i) = 6. Calcule o silhouette da observação e interprete. *(0,5)*

c) Indique duas limitações do K-means. *(0,5)*

QUADRO DA FOLHA DE APOIO — CAIXA 8

8. Classificatória (clustering) T4 T11 M2-5 M2-6 M2-11

- Grupos **desconhecidos** · não supervisionado · homogéneo dentro, distinto entre. Distância euclidiana $\sqrt{\Sigma(p-q)^2}$; padronizar (resolve escala, **não outliers**)
- **T4 hierárquico aglomerativo:** cada observação começa num cluster e agregam-se sucessivamente os mais próximos até 1. Dendrograma: altura = distância, corte define k (escolhido *depois*). Ligação: simples=mín · completa=máx · Ward=menor aumento da variância interna
- **K-means:** k prévio → centros iniciais → atribuir ao mais próximo → recalcular → repetir. Numérico
- **Silhouette** s=(b−a)/max(a,b): **≈1** bem integrada e afastada dos outros · **≈0** fronteira · **negativo**: possivelmente mal atribuída (mais perto de outro cluster) [M2-6]
- **T11c:** K=2/3/4 → 0,44/**0,61**/0,52 → **K=3** (maior silhouette = melhor coesão e separação)
- **M2-11a:** 0,43/**0,57**/0,49, menor cluster 38%/18%/4% → **K=3**; K=4 pior e cluster de 4% pede cautela. Ver também tamanho, estabilidade, interpretabilidade
- **Limitações do K-means [T11d, M2-11b]:** k definido à partida · sensível à inicialização dos centroides · sensível a outliers/escala · favorece clusters compactos de forma/densidade semelhante
- Caracterizar com médias **e** dispersão e tamanho · taxa do cluster (21%) ≠ prob. individual · silhouette alto ⇏ "grupos verdadeiros"

Questão 12. Um modelo discriminante prevê o abandono de clientes (classe positiva: "Abandona"). Obteve-se: 2,5 val.

	Previsto: Abandona	Previsto: Não abandona
Real: Abandona	54	26
Real: Não abandona	18	102

a) Identifique TP, FN, FP e TN. *(0,5)*

b) Calcule a accuracy, o recall e a precision para a classe "Abandona". *(1,0)*

c) Explique por que razão avaliar o modelo apenas nos dados de treino pode ser otimista. *(0,5)*

d) Com p = 4 variáveis explicativas e K = 3 grupos, qual é o número máximo de funções discriminantes? *(0,5)*

QUADRO DA FOLHA DE APOIO — CAIXA 9

9. Discriminante e classificação T5 T12 M2-5 M2-12

- Grupos **conhecidos** · supervisionada · **separa e classifica** em grupos previamente definidos · função $D=a_0+a_1X_1+\ldots$; nº máx. funções $\min(p,K-1)$
- **M2-5:** clustering = grupos desconhecidos (não supervisionado) · discriminante = grupos conhecidos (supervisionado)
- **Matriz de confusão** (linhas=real, colunas=previsto): TP, FN, FP, TN
- `Acc=(TP+TN)/N · Recall=TP/(TP+FN) · Prec=TP/(TP+FP)` · F1=2PR/(P+R) · BalAcc=média dos recalls
- **T12** [30 20 / 10 40], positiva=Com doença: TP30 FN20 FP10 TN40 · acc=70/100=**0,70** · recall=30/50=**0,60** · prec=30/40=**0,75**
- **M2-12** [36 14 / 9 41], positiva=Em risco: TP36 FN14 FP9 TN41 · N=100 · acc=**77%** · recall=36/50=**72%** · prec=36/45=**80%** (F1≈0,758)
- **Avaliar no treino é otimista:** o modelo foi ajustado aos mesmos dados → teste independente ou validação cruzada
- Accuracy alta pode enganar com grupos desequilibrados → ver por grupo · FP = erro tipo I · FN = erro tipo II · coeficientes ≠ causa
- Pressupostos: normalidade multivariada, covariâncias iguais (Box, $p<0,05$ = evidência contra)

Resolução do teste de treino

Respostas, cotação e remissões para o guia e para a folha de apoio. Só consultar depois de fazer o teste.

Grupo I — Escolha múltipla (0,8 valores cada)

Questão 1

0,8 · quadro: caixa 2

> **Resposta: c)** média > mediana > moda.

Com cauda longa à direita, os valores extremos altos puxam a média para cima; a mediana fica no meio e a moda no pico. Cauda à esquerda: média < mediana < moda; simétrica: valores aproximadamente iguais. *[Análise Preliminar, p. 26]*

Questão 2

0,8 · quadro: caixa 3

> **Resposta: b)** duas variáveis ordinais.

Spearman usa ordens (ranks) e mede associação monótona; é adequado a ordinais/rankings. a) e d) são nominais/categóricas → χ^2 + V; c) quantitativa × binária → ponto-bisserial. *[Slides 18/09, p. 20 e 45]*

Questão 3

0,8 · quadro: caixa 6

> **Resposta: b)** a variável tem uma relação forte e positiva com essa componente.

Loading = relação entre variável e componente (intensidade e sinal). a) descreve um *score*; c) a PCA não estabelece causalidade; d) a componente nunca explica, por si só, toda a variância. *[PCA, p. 18 a 22]*

Questão 4

0,8 · quadro: caixa 8

> **Resposta: b)** o resultado pode depender da inicialização dos centros.

a) falso: k é definido à partida; c) falso: a distância euclidiana não é diretamente adequada a nominais; d) o dendrograma é do hierárquico. *[Análise Classificatória, p. 11 e 12; Exercícios Classificatória, Ex. 4]*

Questão 5

0,8 · quadro: caixa 9

> **Resposta: c)** TP / (TP + FN).

a) é a precision; b) é a accuracy; d) é a especificidade (não aparece nos slides). Recall: dos que realmente pertencem ao grupo, quantos foram identificados. *[Análise Discriminante, p. 14]*

Grupo II — Respostas abertas

Questão 6 — Tipos de variável

2,0 · quadro: caixa 1

> **a)** quantitativa **discreta** (contagem). **b)** qualitativa **ordinal** (ordem natural). **c)** quantitativa **contínua** (medição). **d)** qualitativa **nominal** (sem ordem).

0,5 por alínea. *[Análise Preliminar, p. 7 a 10]*

Questão 7 — Qui-quadrado

2,5 · quadro: caixa 5

> **a)** Tabela de contingência 2×2 e **teste do qui-quadrado de independência**. H_0: grupo etário e subscrição são independentes; H_1: existe associação. *(0,5)*
> **b)** E = 100 × 75 / 200 = **37,5**. As restantes esperadas são 62,5, 37,5 e 62,5: todas ≥ 5, logo a condição de aplicação parece satisfeita. *(0,5)*
> **c)** Como p = 0,03 < 0,05, rejeita-se H_0: há evidência de associação entre grupo etário e subscrição. V = 0,15 indica intensidade **fraca**: significativa, mas pouco forte (significância ≠ intensidade). *(1,0)*
> **d) Não**: associação não implica causalidade; podem existir outros fatores (rendimento, canal de contacto), causalidade inversa ou acaso. *(0,5)*

Verificação (meu cálculo): χ^2 = 1,5 + 0,9 + 1,5 + 0,9 = 4,8, gl = 1, p ≈ 0,029; V = √(4,8/200) ≈ 0,155, coerente com o enunciado. *[Slides 18/09, p. 40 a 44; ACS_ACM, p. 6 a 8]*

Questão 8 — Correlação

2,0 · quadro: caixa 4

a) Direção **positiva** (mais horas de formação tendem a acompanhar maior produtividade); intensidade **forte** ($r = 0{,}71$); $p < 0{,}001$: evidência estatística contra a ausência de correlação linear. *(1,0)*
b) Não. A correlação não demonstra causalidade: pode haver causalidade inversa (trabalhadores mais produtivos recebem mais formação), um terceiro fator (motivação, antiguidade) ou acaso. *(0,5)*
c) Não. $r \approx 0$ indica apenas ausência de associação **linear**; pode existir uma relação não linear (por exemplo em U). *(0,5)*

[Slides 18/09, p. 9 a 13 e 47 a 54; Modelo de Exame 2, Resolução, Q8]

Questão 9 — PCA

3,0 · quadro: caixa 6

a) KMO = 0,81 indica boa adequação; Bartlett com $p < 0{,}001$ rejeita H_0: $R = I$, logo há correlação suficiente entre as variáveis. A PCA é adequada. *(0,5)*
b) Pelo Kaiser ($\lambda > 1$): **2 componentes** (2,90 e 1,30). *(0,5)*
c) C1 = 2,90 / 5 = **58%**; C2 = 1,30 / 5 = 26%; acumulada = **84%**. (A soma dos valores próprios é 5 = p.) *(1,0)*
d) C1: loadings altos em rendimento (0,93), escolaridade (0,91) e emprego (0,89): dimensão de *condições socioeconómicas* (desenvolvimento socioeconómico). **C2:** loadings altos em internet (0,80) e participação cultural (0,80): *conectividade e participação cultural*. Os nomes são interpretações, não variáveis observadas. *(1,0)*

[PCA, p. 7 a 19]. A percentagem λ/p com variáveis padronizadas é [complemento]; no exemplo dos slides, 3,62/8 = 45,3% [PCA, p. 10].

Questão 10 — ACS

2,0 · quadro: caixa 7

a) Dimensão 1: 0,150/0,200 = **75%**; dimensões 1 e 2: (0,150 + 0,040)/0,200 = **95%**; por representar: 100% − 95% = **5%**. *(0,75)*
b) Mais contribui: **Online** (50%). Maior |coordenada|: **50+** (−0,72). **Não são a mesma**: uma coordenada elevada não implica contribuição elevada. Melhor representada na dimensão 1: **50+** ($\cos^2 = 0{,}90$). *(0,75)*
c) i) **F**; ii) **F**; iii) **V**. *(0,5)*

[ACS_ACM, p. 10, 13, 14, 20 e 23; Exercícios ACS/ACM, Ex. 3, 4.3, 4.4 e 5.2]

Questão 11 — Clustering

2,0 · quadro: caixa 8

a) K = 4 tem a maior silhouette (0,52), mas o menor cluster tem apenas 3% das observações: solução possivelmente pouco útil ou instável. **Não se escolhe automaticamente.** K = 3 (0,47; menor cluster 22%) é uma escolha razoável; decide-se também pela estabilidade, tamanho e interpretabilidade dos grupos. (Aceita-se K = 4 se for bem justificado com estabilidade e interpretação.) *(1,0)*
b) $s(i) = (b - a)/\max(a, b) = (6 - 3)/6 =$ **0,5**: observação razoavelmente bem integrada no seu cluster. *(0,5)*
c) Por exemplo: k definido à partida; sensível à inicialização dos centros; sensível a outliers e à escala; favorece clusters compactos de tamanho/variância semelhantes; só dados numéricos. *(0,5)*

[Análise Classificatória, p. 11 a 15 e 21; Clustering, p. 18 a 20; Exercícios Classificatória, Ex. 5d; Modelo de Exame 2, Resolução, Q11]

Questão 12 — Discriminante

2,5 · quadro: caixa 9

a) TP = 54; FN = 26; FP = 18; TN = 102 (N = 200). *(0,5)*
b) Accuracy = (54 + 102)/200 = **78%**; recall = 54/(54 + 26) = 54/80 = **67,5%**; precision = 54/(54 + 18) = 54/72 = **75%**. *(1,0)*
c) Porque o modelo foi ajustado aos mesmos dados em que é avaliado; a capacidade de classificar novas observações deve estimar-se com uma amostra de teste independente ou validação cruzada. *(0,5)*
d) $\min(p, K - 1) = \min(4, 2) =$ **2** funções. *(0,5)*

(Extra, meu cálculo: F1 = 2·0,75·0,675/(0,75 + 0,675) ≈ 0,71; recall de "Não abandona" = 102/120 = 85%; balanced accuracy = (67,5% + 85%)/2 ≈ 76,3%.) [Análise Discriminante, p. 10 a 19; Modelo de Exame 2, Resolução, Q12]

Autoavaliação por tema

Preenche a pontuação que obtiveste e vê onde perdeste pontos:

Tema	Questões	Máximo	Obtido	Se perdeste pontos, revê
Dados e descritiva	1, 6	2,8		Guia §1 e §5.1; folha: caixas 1 e 2
Associação (r, χ^2, V)	2, 7, 8	5,3		Guia §4.1; folha: caixas 3 a 5
PCA	3, 9	3,8		Guia Q9, M2-9, §4.3; folha: caixa 6
ACS / ACM	10	2,0		Guia Q10, M2-10, §4.4; folha: caixa 7
Clustering	4, 11	2,8		Guia Q11, M2-11, §4.5; folha: caixa 8
Discriminante e classificação	5, 12	3,3		Guia Q12, M2-12; folha: caixa 9
Total		**20,0**		

Regra: tema abaixo de 60% da pontuação → refazer as questões desse tema do guia antes do exame. Se algum cálculo falhou, refaz-o à mão sem consultar o quadro.