Análise de Dados — Resolução do teste de treino

Respostas, cotação e remissões para o guia e para a folha de apoio. Abrir só depois de fazer o teste.

Grupo I — Escolha múltipla (0,8 valores cada)

Questão 1

0,8 · quadro: caixa 2

> **Resposta: c)** média > mediana > moda.

Com cauda longa à direita, os valores extremos altos puxam a média para cima; a mediana fica no meio e a moda no pico. Cauda à esquerda: média < mediana < moda; simétrica: valores aproximadamente iguais. *[Análise Preliminar, p. 26]*

Questão 2

0,8 · quadro: caixa 3

> **Resposta: b)** duas variáveis ordinais.

Spearman usa ordens (ranks) e mede associação monótona; é adequado a ordinais/rankings. a) e d) são nominais/categóricas → χ^2 + V; c) quantitativa × binária → ponto-bisserial. *[Slides 18/09, p. 20 e 45]*

Questão 3

0,8 · quadro: caixa 6

> **Resposta: b)** a variável tem uma relação forte e positiva com essa componente.

Loading = relação entre variável e componente (intensidade e sinal). a) descreve um *score*; c) a PCA não estabelece causalidade; d) a componente nunca explica, por si só, toda a variância. *[PCA, p. 18 a 22]*

Questão 4

0,8 · quadro: caixa 8

> **Resposta: b)** o resultado pode depender da inicialização dos centros.

a) falso: k é definido à partida; c) falso: a distância euclidiana não é diretamente adequada a nominais; d) o dendrograma é do hierárquico. *[Análise Classificatória, p. 11 e 12; Exercícios Classificatória, Ex. 4]*

Questão 5

0,8 · quadro: caixa 9

> **Resposta: c)** TP / (TP + FN).

a) é a precision; b) é a accuracy; d) é a especificidade (não aparece nos slides). Recall: dos que realmente pertencem ao grupo, quantos foram identificados. *[Análise Discriminante, p. 14]*

Grupo II — Respostas abertas

Questão 6 — Tipos de variável

2,0 · quadro: caixa 1

> **a)** quantitativa **discreta** (contagem). **b)** qualitativa **ordinal** (ordem natural). **c)** quantitativa **contínua** (medição). **d)** qualitativa **nominal** (sem ordem).

0,5 por alínea. *[Análise Preliminar, p. 7 a 10]*

Questão 7 — Qui-quadrado

2,5 · quadro: caixa 5

> **a)** Tabela de contingência 2×2 e **teste do qui-quadrado de independência**. H_0: grupo etário e subscrição são independentes; H_1: existe associação. *(0,5)*
> **b)** E = 100 × 75 / 200 = **37,5**. As restantes esperadas são 62,5, 37,5 e 62,5: todas ≥ 5, logo a condição de aplicação parece satisfeita. *(0,5)*
> **c)** Como p = 0,03 < 0,05, rejeita-se H_0: há evidência de associação entre grupo etário e subscrição. V = 0,15 indica intensidade **fraca**: significativa, mas pouco forte (significância ≠ intensidade). *(1,0)*
> **d) Não**: associação não implica causalidade; podem existir outros fatores (rendimento, canal de contacto), causalidade inversa ou acaso. *(0,5)*

Verificação (meu cálculo): χ^2 = 1,5 + 0,9 + 1,5 + 0,9 = 4,8, gl = 1, p ≈ 0,029; V = √(4,8/200) ≈ 0,155, coerente com o enunciado. *[Slides 18/09, p. 40 a 44; ACS_ACM, p. 6 a 8]*

Questão 8 — Correlação

2,0 · quadro: caixa 4

a) Direção **positiva** (mais horas de formação tendem a acompanhar maior produtividade); intensidade **forte** ($r = 0{,}71$); $p < 0{,}001$: evidência estatística contra a ausência de correlação linear. *(1,0)*
b) Não. A correlação não demonstra causalidade: pode haver causalidade inversa (trabalhadores mais produtivos recebem mais formação), um terceiro fator (motivação, antiguidade) ou acaso. *(0,5)*
c) Não. $r \approx 0$ indica apenas ausência de associação **linear**; pode existir uma relação não linear (por exemplo em U). *(0,5)*

[Slides 18/09, p. 9 a 13 e 47 a 54; Modelo de Exame 2, Resolução, Q8]

Questão 9 — PCA

3,0 · quadro: caixa 6

a) KMO = 0,81 indica boa adequação; Bartlett com $p < 0{,}001$ rejeita H_0: $R = I$, logo há correlação suficiente entre as variáveis. A PCA é adequada. *(0,5)*
b) Pelo Kaiser ($\lambda > 1$): **2 componentes** (2,90 e 1,30). *(0,5)*
c) C1 = 2,90 / 5 = **58%**; C2 = 1,30 / 5 = 26%; acumulada = **84%**. (A soma dos valores próprios é 5 = p.) *(1,0)*
d) C1: loadings altos em rendimento (0,93), escolaridade (0,91) e emprego (0,89): dimensão de *condições socioeconómicas* (desenvolvimento socioeconómico). **C2:** loadings altos em internet (0,80) e participação cultural (0,80): *conectividade e participação cultural*. Os nomes são interpretações, não variáveis observadas. *(1,0)*

[PCA, p. 7 a 19]. A percentagem λ/p com variáveis padronizadas é [complemento]; no exemplo dos slides, 3,62/8 = 45,3% [PCA, p. 10].

Questão 10 — ACS

2,0 · quadro: caixa 7

a) Dimensão 1: 0,150/0,200 = **75%**; dimensões 1 e 2: (0,150 + 0,040)/0,200 = **95%**; por representar: 100% − 95% = **5%**. *(0,75)*
b) Mais contribui: **Online** (50%). Maior |coordenada|: **50+** (−0,72). **Não são a mesma**: uma coordenada elevada não implica contribuição elevada. Melhor representada na dimensão 1: **50+** ($\cos^2 = 0{,}90$). *(0,75)*
c) i) **F**; ii) **F**; iii) **V**. *(0,5)*

[ACS_ACM, p. 10, 13, 14, 20 e 23; Exercícios ACS/ACM, Ex. 3, 4.3, 4.4 e 5.2]

Questão 11 — Clustering

2,0 · quadro: caixa 8

a) K = 4 tem a maior silhouette (0,52), mas o menor cluster tem apenas 3% das observações: solução possivelmente pouco útil ou instável. **Não se escolhe automaticamente.** K = 3 (0,47; menor cluster 22%) é uma escolha razoável; decide-se também pela estabilidade, tamanho e interpretabilidade dos grupos. (Aceita-se K = 4 se for bem justificado com estabilidade e interpretação.) *(1,0)*
b) $s(i) = (b - a)/\max(a, b) = (6 - 3)/6 =$ **0,5**: observação razoavelmente bem integrada no seu cluster. *(0,5)*
c) Por exemplo: k definido à partida; sensível à inicialização dos centros; sensível a outliers e à escala; favorece clusters compactos de tamanho/variância semelhantes; só dados numéricos. *(0,5)*

[Análise Classificatória, p. 11 a 15 e 21; Clustering, p. 18 a 20; Exercícios Classificatória, Ex. 5d; Modelo de Exame 2, Resolução, Q11]

Questão 12 — Discriminante

2,5 · quadro: caixa 9

a) TP = 54; FN = 26; FP = 18; TN = 102 (N = 200). *(0,5)*
b) Accuracy = (54 + 102)/200 = **78%**; recall = 54/(54 + 26) = 54/80 = **67,5%**; precision = 54/(54 + 18) = 54/72 = **75%**. *(1,0)*
c) Porque o modelo foi ajustado aos mesmos dados em que é avaliado; a capacidade de classificar novas observações deve estimar-se com uma amostra de teste independente ou validação cruzada. *(0,5)*
d) $\min(p, K - 1) = \min(4, 2) =$ **2** funções. *(0,5)*

(Extra, meu cálculo: F1 = 2·0,75·0,675/(0,75 + 0,675) ≈ 0,71; recall de "Não abandona" = 102/120 = 85%; balanced accuracy = (67,5% + 85%)/2 ≈ 76,3%.) [Análise Discriminante, p. 10 a 19; Modelo de Exame 2, Resolução, Q12]

Autoavaliação por tema

Preenche a pontuação que obtiveste e vê onde perdeste pontos:

Tema	Questões	Máximo	Obtido	Se perdeste pontos, revê
Dados e descritiva	1, 6	2,8		Guia §1 e §5.1; folha: caixas 1 e 2
Associação (r, χ^2, V)	2, 7, 8	5,3		Guia §4.1; folha: caixas 3 a 5
PCA	3, 9	3,8		Guia Q9, M2-9, §4.3; folha: caixa 6
ACS / ACM	10	2,0		Guia Q10, M2-10, §4.4; folha: caixa 7
Clustering	4, 11	2,8		Guia Q11, M2-11, §4.5; folha: caixa 8
Discriminante e classificação	5, 12	3,3		Guia Q12, M2-12; folha: caixa 9
Total		**20,0**		

Regra: tema abaixo de 60% da pontuação → refazer as questões desse tema do guia antes do exame. Se algum cálculo falhou, refaz-o à mão sem consultar o quadro.