Anexo de Utilização de Inteligência Artificial

Questão 9.5 – Key Influencers · LogiDistrib · máx. 2 páginas

Estudante: [NOME]	**Código do conjunto de dados:** [CÓDIGO]	**Data:** [dd/mm/aaaa]

[Rever antes de entregar: confirmar que cada interação corresponde ao que realmente fez, acrescentar as correções que fizer ao construir o .pbix e apagar esta linha.]

1. Ferramentas utilizadas

Ferramenta	Para que foi usada	Data
ChatGPT (OpenAI) [modelo/versão]	**Questão 9:** aprender o visual Key Influencers, perceber como o configurar para as entregas atrasadas e que variáveis excluir por fuga de informação.	[dd/mm/aaaa]
Claude (Anthropic) [modelo/versão]	Apoio passo a passo na construção do .pbix (Power Query, colunas e medidas DAX, visuais) e **cálculos independentes de conferência** (Python, SQL); rascunho da nota. Validei cada resultado no Power BI.	10–15/10/2026

Os valores calculados fora do Power BI serviram apenas para **conferir** resultados; o modelo, as colunas calculadas e as medidas foram construídos no Power BI e nada foi importado de ferramentas externas.

2. Interações importantes (Q9)

Tema	O que perguntei (resumo)	O que a IA respondeu (resumo)	Como usei / verifiquei
1. Aprender e configurar o visual (ChatGPT)	«Vou usar o visual Key Influencers nas entregas atrasadas; como funciona?». Depois indiquei as colunas de `encomendas` e a minha medida `n_enc_atrasadas` (com o DAX).	Explicou que Analisar = variável a explicar e Explicar por = fatores; distinguiu **contar** atrasos de **identificar influenciadores**; propôs uma coluna Atrasada/No prazo ao nível da encomenda. Reconheceu que a medida `n_enc_atrasadas` não serve em «Analisar».	Usei a coluna que já tinha (`entrega_atrasada`, só «Atrasada» e «No prazo»), em Analisar, e a medida só em cartões.
2. Variáveis explicativas (ChatGPT)	«Identifica por bullet points os fatores importantes para o conjunto de dados.»	Listou `custo_transporte` e `tentativas_entrega` como fatores a usar, e também as datas, `entrega_atrasada` e `id_encomenda`. Não considerou atributos de cliente, serviço, prioridade, peso, transportadora ou centro.	**Rejeitei** a lista: `id_encomenda` é só um identificador, as datas definem o atraso e a variável a explicar não é fator. **Alarguei** às dimensões (região do cliente, serviço, prioridade, peso, centro, transportadora).
3. Fuga de informação (ChatGPT)	«Qual das colunas não devo usar por fuga de informação, circularidade ou informação que ainda não existe na decisão?»	Apontou `data_entrega` e `entrega_atrasada` (circularidade) e `id_encomenda`; sobre `custo_transporte` e `tentativas_entrega` disse apenas «usar com precaução», sem concluir.	**Completei com os dados:** ≥ 2 tentativas → 57 % atrasadas (1 tentativa: 10 %); custo médio 8,70 € → 13,33 € → 17,35 € com 1/2/3 tentativas (re-entrega). **Excluí as duas** (só se conhecem depois da entrega; o custo contém o resultado).
4. Validar e interpretar (Claude)	«Como verifico no Power BI o padrão do visual e o que posso concluir?»	Matriz de % atrasadas por região × serviço, transportadora e centro (o padrão mantém-se: 2,1×–2,4×); os 29 clientes do Interior um a um; alertou que o visual mostra associação, não causa.	Construí a matriz, comparei-a com o visual e usei o Interior como prioridade (Q8), com impacto quantificado.

3. Sugestões da IA corrigidas, rejeitadas ou melhoradas

Rejeitada – conjunto de variáveis do ChatGPT. Propunha explicar os atrasos só com `custo_transporte` e `tentativas_entrega`, precisamente as que mais fuga de informação introduzem: um visual construído assim «acertaria» por consequência do atraso (re-entregas), sem ajudar a decidir. Retirei-as e usei variáveis conhecidas no registo da encomenda.

Corrigida – lista de «fatores». Datas e identificador não são fatores explicativos; a própria resposta seguinte da IA reconheceu-o para o identificador (inconsistência entre respostas).

Adaptada – exemplos genéricos. O ChatGPT usou nomes que não existem no meu modelo (tabela `Entregas`, `Estado_Entrega`, `COUNTROWS(Entregas)`); adaptei ao modelo real (as entregas estão fundidas em `encomendas`; já existia `entrega_atrasada`).

Erros ao implementar e como os resolvi (Claude). (a) Fórmulas criadas como **medida** em vez de **coluna calculada** davam «A single value for column … cannot be determined»: recriei-as como colunas em `encomendas`; (b) `LOOKUPVALUE` falhava por tipos incompatíveis (data vs texto): corrigi os tipos no Power Query; (c) a consulta `encomendas` não incluía as colunas das entregas: fundi as duas tabelas (1:1). **Decisão – dias úteis (Q3):** o DAX não tem `NETWORKDAYS` (função do Excel), por isso usei um contador de dias úteis no calendário (du_antes) e a convenção [encomenda ; expedição[, que muda o resultado: 93,8 % / 91,1 % / 81,4 % / 68,9 % consoante a convenção.

4. O que aprendi

Key Influencers: o visual ajusta um modelo e compara cada categoria com todas as restantes; mostra associações, não causas; é sensível a variáveis redundantes e a fugas de informação, e um fator importante pode explicar pouco do fenómeno (mesmo no Interior, a maioria das entregas chega a tempo). Por isso validei sempre com uma análise independente (matriz) e por estratos (serviço, transportadora, centro) para excluir confundidores.

Rigor com a IA: as ferramentas aceleram, mas erraram em detalhes (lista de variáveis do ChatGPT com fuga de informação, função inexistente em DAX, convenção de dias úteis). Cada medida foi verificada contra um cálculo independente e as convenções (dias úteis, período comparável, custo logístico por produto) ficaram explícitas e justificadas, porque mudam as conclusões.