Faculdade de Economia · Universidade do Porto · 2026/2027

Avaliação crítica do Relatório de Análise e Segmentação de Clientes (R5)

Trabalho Prático — Análise de Dados · Relatório do consultor independente

Autor: [Nome do estudante] — [N.º de estudante]

Unidade curricular: Análise de Dados

Documento avaliado: “Relatório de Análise e Segmentação de Clientes”, R5 — Relatório do Analista (10 pp.)

Data de entrega: 26 de outubro de 2026

1. Enquadramento e resposta à questão central

A empresa pretende compreender o perfil dos clientes, identificar segmentos distintos e dispor de um sistema para classificar novos clientes. O analista apresentou um relatório (R5) com análise descritiva, bivariada, Análise de Componentes Principais (PCA) e *K-means* sobre 300 clientes e 19 variáveis. Como consultor independente, avalio as opções metodológicas, a interpretação dos resultados e a validade das conclusões, sem reproduzir toda a análise; limitei-me a **verificar a consistência interna** dos números publicados (Anexo B).

> **Resposta à questão central. Não, na sua forma atual.** O relatório é uma boa *exploração inicial* e produz uma hipótese de segmentação plausível (três perfis: elevado valor, jovens digitais, tradicionais insatisfeitos) e um resultado inferencial sólido (o abandono difere entre clusters, $p = 0{,}006$). Mas (i) **não aborda a classificação de novos clientes**, um dos três objetivos da empresa; (ii) a **estrutura de clusters é fraca** (silhuetas 0,21–0,35) e a escolha de $k = 3$ está insuficientemente justificada e validada; (iii) contém **uma afirmação metodologicamente errada**, **afirmações sem suporte** e **inconsistências numéricas e gráficas** (incluindo uma legenda de clusters que contradiz a tabela de caracterização); e (iv) algumas conclusões sobre abandono vão além do que os dados permitem. Recomendo usar o trabalho como ponto de partida, **não** como regra operacional.

Etapa	Avaliação	Razão principal
Dados e valores em falta	**Parcialmente adequada**	Eliminação *listwise* aceitável pela dimensão, mas sem testar o mecanismo de falta; sem tratamento de *outliers*; variáveis sem definição.
Análise bivariada	**Parcialmente adequada**	Testes corretos, mas Pearson em variáveis assimétricas/discretas, V de Cramér com erro e sobre-interpretação do método de pagamento ($p = 0{,}065$).
PCA	**Adequada, com falhas**	Escolha de 2 componentes defensável; valores próprios inconsistentes; "*loadings*" são vetores próprios; rótulos interpretativos fortes.
K-means e escolha de k	**Insuficiente**	Afirmação errada sobre *outliers*; k contra o critério usado; sem estabilidade; estrutura fraca omitida; legenda da Fig. 1 trocada.
Ligação ao abandono	**Adequada, com ressalvas**	Resultado estatisticamente válido, mas associativo, sem validação preditiva nem ordem temporal; "diferenças nas categóricas" sem evidência.
Classificação de novos clientes	**Não abordada**	Sem regra de atribuição, classificador ou validação; variáveis usadas não existem para um cliente recente.

2. Dados e tratamento preliminar

Pontos positivos. O identificador foi excluído, reporta-se n, valores em falta e estatísticas descritivas, e as médias ponderadas dos clusters (Tabela 10) reproduzem as médias globais da Tabela 2, o que indica coerência dos cálculos de base.

Valores em falta. Faltam 9 (rendimento), 6 (% digital) e 6 (satisfação) valores; 280 casos completos (93,3%). A eliminação *listwise* é defensável com perdas tão baixas, **mas só se a falta for aleatória (MCAR)**, o que não é testado nem discutido. O rendimento é uma variável sensível em que a não-resposta pode depender do próprio valor (MNAR). Há indícios que impedem presumir ignorabilidade: a partir das taxas de abandono por cluster (5, 8 e 31 abandonos) deduz-se que os 20 clientes excluídos incluem **6 abandonos (30%)**, contra 15,7% nos

280 completos. A diferença não é conclusiva (Fisher, $p \approx 0{,}12$, n pequeno), mas é um sinal de alerta. Acresce que **20 clientes ficam sem segmento** e que, para **novos clientes**, a eliminação de casos não é utilizável. Alternativas: imputação múltipla (MICE) ou por vizinhos mais próximos, com análise de sensibilidade.

Natureza das variáveis. A satisfação (4–10) é ordinal; visitas, produtos e reclamações são contagens; a % digital é limitada a [0;100]. Todas são tratadas como contínuas (Pearson, PCA, distância euclidiana) sem discussão. Faltam definições: escala da satisfação, unidades (€, anos), e o significado de *Perfil* (A/B/C, três grupos quase iguais) e *Fidelização* (exatamente 50/50, o que sugere um corte pela mediana). Se *Perfil* for uma segmentação já existente, devia ser comparado com os clusters; *Grupo etário* é derivado da idade.

Distribuições e *outliers*. A análise assenta apenas em média *vs.* mediana. "Idade relativamente equilibrada" é inferida só dessa comparação; não há histogramas nem caixas-de-bigodes. Rendimento (máx. 5 544, 3,7 DP acima da média) e despesa (máx. 241, 3,7 DP) mostram cauda direita pronunciada e valores extremos que o relatório menciona sem tratar. A amostra (300) não é descrita (seleção, representatividade) e contém apenas 50 abandonos, o que limita a modelação. A Tabela 3 omite sexo, grupo etário e **método de pagamento**, precisamente a variável que depois é destacada.

3. Análise bivariada

Correlações. A matriz de Pearson é um primeiro olhar razoável e as leituras (rendimento–despesa $r = 0{,}84$; idade–% digital $r = -0{,}62$) são plausíveis. Reservas: (i) rendimento e despesa são assimétricos e as restantes variáveis discretas, pelo que Spearman (ou Pearson com transformação logarítmica) seria mais robusto; (ii) não há valores-*p*, intervalos de confiança nem diagramas de dispersão; (iii) a tabela mostra só as correlações "principais", uma seleção sem critério declarado; (iv) a conclusão de que rendimento, despesa e produtos medem "uma mesma dimensão de **valor do cliente**" confunde o *rendimento do cliente* com o *valor do cliente para a empresa*, que exigiria receita, margem ou CLV. É uma inferência, não um facto.

Qui-quadrado e V de Cramér. A escolha é apropriada (categóricas *vs.* abandono binário). Recalculei as oito linhas da Tabela 5: p-values e V conferem em sete; **para a Região, V = 0,039 está errado: $\sqrt{(1{,}364/300)} = 0{,}067$**. Não altera a conclusão, mas mostra falta de revisão. Não se verificam as frequências esperadas (≥ 5) nem se discute a multiplicidade de testes (oito, sem correção).

Método de pagamento. Com $p = 0{,}065$ e V = 0,155 o teste **não é significativo**, mas o relatório conclui que o método "poderá ser um fator relevante para a retenção", destacando taxas de 23,5% (crédito) a 9,9% (débito) sem *n* por categoria nem intervalos de confiança. Fidelização ($p = 0{,}088$) e Perfil ($p = 0{,}090$) estão na mesma situação e não merecem referência: o critério é inconsistente. Aceito a observação como **hipótese a testar**, não como conclusão. Por fim, o abandono nunca é cruzado com as variáveis quantitativas (satisfação, reclamações, produtos…), a análise mais natural face ao objetivo.

4. Análise de Componentes Principais

Adequação. KMO = 0,823 ("meritório") é adequado como diagnóstico; o teste de Bartlett ($\chi^2 = 1295{,}6$) é pouco informativo, pois com correlações desta ordem e $n = 280$ rejeita-se quase sempre a identidade. Não se apresentam MSA individuais. Recalculado a partir dos valores próprios, o χ^2 de Bartlett dá $\approx 1286{,}6$, próximo do reportado.

Inconsistências numéricas (Tabela 6). Numa PCA sobre a matriz de correlação de 9 variáveis os valores próprios somam 9, mas os reportados somam **9,033**; a variância do CP1 (42,58%) não corresponde a 3,846/9 = 42,73%; as percentagens somam 100,08% enquanto o acumulado final é 100,00%. São diferenças pequenas e sem efeito no número de componentes, mas indicam arredondamentos mal geridos ou valores de execuções diferentes, e devem ser corrigidas e documentadas.

Número de componentes. O critério de Kaiser ($\lambda > 1$) conduz a dois componentes (67,06% da variância). A decisão é **defensável** (há uma quebra nítida entre $\lambda_2 = 2{,}21$ e $\lambda_3 = 0{,}83$), mas apoia-se num critério frequentemente criticado, num *scree plot* que "parece confirmar" sem ser mostrado, e não considera a análise paralela (Horn, 1965). Perdem-se 33% da variância, relevante para a leitura da Figura 1.

Interpretação. A Tabela 7 apresenta vetores próprios (norma unitária), não *loadings* no sentido de correlações componente–variável (que são coeficiente × √λ: p. ex., despesa–CP1 = 0,90; % digital–CP2 = 0,86). A leitura é **seletiva e sem limiar explícito**: no CP1 cita-se antiguidade (0,298) mas não satisfação (0,285). O CP1 é um fator geral de intensidade/"tamanho"; o rótulo "valor" é uma leitura económica não demonstrada. O CP2 (idade e antiguidade negativas, % digital positiva, satisfação 0,385) descreve melhor "clientes jovens/recentes e digitais" do que "modernização". Por fim, a PCA **não é usada na segmentação** (só na visualização), pelo que o objetivo de "representação mais simples" fica apenas parcialmente cumprido.

5. Análise de clusters (*K-means*)

5.1 Pré-processamento e pressupostos

A padronização é necessária e adequada. Porém, o relatório afirma que ela "garante que a solução de K-means não seja afetada de forma relevante pelos valores extremos". **Esta afirmação está errada.** A normalização (*z-score*) é uma transformação linear: não altera a forma da distribuição, os valores extremos continuam a 3,7 DP, a soma de quadrados do K-means continua a penalizá-los fortemente, e a própria média e desvio-padrão usados são afetados por eles. Consequência plausível: o cluster de "elevado valor" (22% dos clientes, rendimento médio 3 648 *vs.* Q3 global de 2 252) pode estar a captar a **cauda direita** de rendimento e despesa. Impõe-se uma análise de sensibilidade (log/*winsorização*, *k*-medoids/PAM).

Há ainda **ponderação implícita**: quatro variáveis de "valor" fortemente correlacionadas (r até 0,84) pesam mais na distância do que, por exemplo, a % digital; usar a distância euclidiana em ordinais/contagens e deixar as categóricas de fora (Gower, K-prototypes) são opções por justificar. Não se indicam inicializações, semente nem repetições, pelo que a análise não é reprodutível.

5.2 Escolha do número de clusters

O coeficiente de silhueta é máximo em $k = 2$ (0,353), mas escolhe-se $k = 3$ (0,325) por ser "mais diferenciada e interpretável". Fazê-lo **não é indefensável**: critérios de negócio são legítimos e o analista foi transparente. Mas a justificação é insuficiente: (i) usa-se um único critério (sem *elbow*, Calinski–Harabasz, *gap* ou estabilidade por *bootstrap*); (ii) **todas as silhuetas** estão na zona de estrutura fraca (0,26–0,50) ou sem estrutura substancial (< 0,25) segundo Kaufman e Rousseeuw (1990), facto omitido nas conclusões, que falam em segmentos "distintos"; (iii) $k = 4$ (0,319) é praticamente equivalente a $k = 3$ e a Figura 1 sugere **quatro nuvens** (o grupo maior divide-se em dois), alternativa não explorada; (iv) não há silhuetas por cluster.

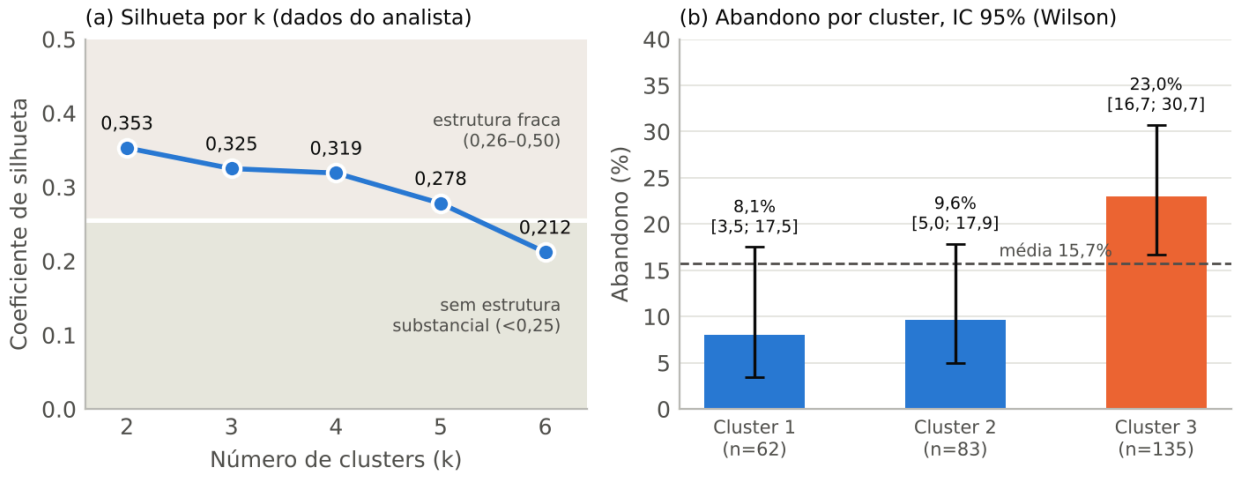


Figura A. (a) Silhueta por *k*, com as faixas de interpretação de Kaufman e Rousseeuw (1990). (b) Taxa de abandono por cluster com IC a 95% de Wilson; abandonos reconstruídos a partir de *n* × taxa (5, 8 e 31). Elaboração própria com dados do R5.

5.3 Caracterização e rotulagem dos clusters

A Tabela 10 apresenta apenas médias: faltam desvios-padrão, perfis padronizados e dispersão. Há **circularidade**: as variáveis que definem os clusters são usadas para os descrever, pelo que as diferenças são, por construção, grandes; servem para descrever, não para validar. Algumas descrições são imprecisas: o Cluster 3 é "mais velho", mas a idade (47,9) é igual à do Cluster 1 (47,2); só difere do Cluster 2. Os Clusters 2 e 3 são **quase idênticos** em rendimento (1 769 *vs.* 1 654), despesa (59,96 *vs.* 59,69) e produtos (2,54 *vs.* 2,40); distinguem-se por idade, digital, antiguidade, satisfação e reclamações. Os rótulos ("elevado valor", "jovens e digitais", "tradicionais") são úteis comercialmente mas são interpretações.

5.4 Representação gráfica: legenda inconsistente

Na Figura 1 do R5 (reproduzida abaixo com anotações), o "Cluster 3" (verde) está no extremo direito do CP1, isto é, rendimento, despesa, produtos e visitas elevados (Tabela 7), e o "Cluster 1" (azul) no lado negativo. Isto **contradiz a Tabela 10**, onde o Cluster 1 é o de valor elevado. As proporções de pixels (≈ 21%, 49%, 31% para verde, azul, laranja) coincidem com 62, 135 e 83 clientes, o que indica que **os rótulos 1 e 3 estão trocados na figura** (ou na tabela). Uma leitura trocada levaria a dirigir ações de retenção ao segmento errado. O texto não comenta o que a figura mostra (separação, sobreposição, sub-grupos).

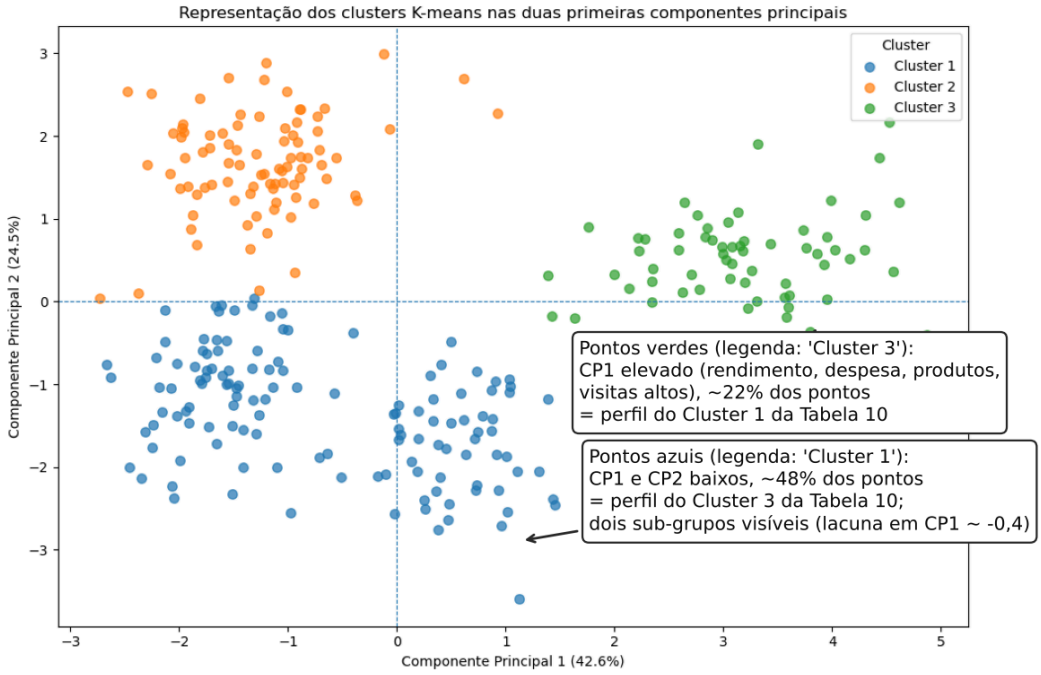


Figura B. Figura 1 do R5 com anotações do consultor. Lacuna visível no grupo azul (CP1 ≈ −0,4), compatível com *k* = 4.

6. Relação dos clusters com variáveis de negócio

O relatório afirma haver "diferenças entre os clusters no grupo etário, plano e método de pagamento", mas **não apresenta tabelas nem testes**. Além disso, o grupo etário deriva da idade (usada na segmentação) e o plano não tinha relação com o abandono (p = 0,994). A afirmação **não é suportada**.

Abandono por cluster. Este é o resultado inferencial mais sólido: 8,1%, 9,6% e 23,0%; reproduzi χ^2 = 10,41 (gl = 2), p = 0,0055 e V = 0,193. O Cluster 3 concentra 31 dos 44 abandonos observados (70%). Reservas: (i) o teste global não indica que pares diferem; os IC (Fig. A, painel b) mostram sobreposição parcial (Cluster 3 [16,7; 30,7] *vs.* Cluster 1 [3,5; 17,5]); (ii) é uma **associação**, não previsão: 77% dos clientes do Cluster 3 *não* abandonaram, e não há sensibilidade, especificidade ou AUC; (iii) desconhece-se a **ordem temporal**: se visitas,

produtos, satisfação ou reclamações forem medidos durante ou após o abandono, o perfil do Cluster 3 pode ser consequência e não causa; (iv) a frase "*demonstra* que este segmento apresenta maior risco" é forte e deve ser "indica/sugere". A prioridade para ações de retenção é razoável como hipótese, mas deve ser testada.

7. Os resultados respondem ao problema da empresa?

- **Perfil dos clientes:** sim, de forma descritiva, com as reservas da secção 2.
- **Segmentos distintos:** parcialmente: existe uma hipótese de segmentação interpretável, mas com estrutura fraca, *k* pouco validado e sensibilidade a extremos por testar.
- **Sistema para classificar novos clientes: não**. O relatório não apresenta centróides nem parâmetros de padronização (regra de atribuição), nenhum classificador supervisionado, nenhuma validação (treino/teste, validação cruzada, estabilidade) e a eliminação *listwise* é inaplicável a novos casos. Sobretudo, as variáveis de segmentação (antiguidade, visitas, despesa, produtos, satisfação, reclamações) **acumulam-se com o tempo e não existem à entrada**: um cliente recém-chegado terá antiguidade ≈ 0 e quase nenhum histórico de visitas ou produtos, pelo que tenderia a parecer-se com o Cluster 2 (o de menor antiguidade e menos visitas), por efeito do tempo e não do seu perfil (inferência, não cálculo). Com 300 clientes e 50 abandonos, a dimensão da amostra limita ainda modelos com muitos preditores.

8. Limitações e alternativas propostas

Limitação	Alternativa proposta
Extremos/assimetria afetam o K-means	Transformação logarítmica ou *winsorização*; *k*-medoids (PAM); comparar soluções.
Estrutura fraca, *k* pouco validado	Mais critérios (*elbow*, Calinski–Harabasz, *gap*); estabilidade por *bootstrap* (Rand ajustado); silhueta por cluster; testar *k* = 2 e 4; modelos de mistura gaussiana.
Falta de dados não aleatória; 20 clientes sem segmento	Comparar excluídos e incluídos; imputação múltipla; análise de sensibilidade.
Variáveis ordinais, contagens e categóricas ignoradas	Spearman; distância de Gower/K-prototypes; incluir plano, canal, região.
Classificação de novos clientes ausente	Modelo supervisionado (multinomial, árvore) com variáveis disponíveis à entrada e validação cruzada; regra do centróide mais próximo documentada.
Abandono só associativo	Regressão logística com variáveis quantitativas e métricas (AUC, *recall*); definir datas de medição; piloto com grupo de controlo.

9. Recomendações para a administração

1. **Não adotar o R5 como regra operacional.** Usá-lo como hipótese de trabalho para discussão com as áreas comercial e de retenção.
2. **Exigir correções prévias:** legendas da Figura 1 face à Tabela 10, afirmação sobre *outliers*, V de Cramér da Região, valores próprios, e suporte para as "diferenças nas categóricas".
3. **Solicitar análises de robustez** (sensibilidade a extremos, *k* alternativos, estabilidade, comparação com *Perfil* A/B/C e imputação) antes de fixar segmentos.
4. **Encomendar um modelo de classificação de novos clientes**, com variáveis disponíveis à entrada e avaliação em dados não vistos; e, em separado, um modelo de risco de abandono.
5. **Testar a retenção em piloto:** ações dirigidas ao segmento com maior abandono, com grupo de controlo, de baixo custo e reversível; acompanhar o método de pagamento como hipótese, não como facto.
6. **Melhorar os dados:** dicionário de variáveis (escalas, unidades, datas), medida de valor real do cliente (margem/CLV) e amostra maior; documentar *software*, semente e código.

10. Conclusão

O R5 cumpre bem a parte descritiva e produz uma segmentação interpretável e uma associação com o abandono estatisticamente suportada. Porém, as fragilidades (estrutura de clusters fraca, justificação incompleta de *k*, afirmação errada sobre *outliers*, inconsistência entre tabela e figura, sobre-interpretação de resultados não significativos e total ausência de classificação de novos clientes) impedem que seja uma base **adequada** para decidir. A resposta à questão central é, assim, "**ainda não**": é um bom ponto de partida que precisa de correções, robustez e de um componente preditivo para servir o objetivo da empresa.

Referências

Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate Data Analysis* (8.ª ed.). Cengage.

Hennig, C. (2015). What are the true clusters? *Pattern Recognition Letters*, *64*, 53–62.

Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. *Psychometrika*, *30*(2), 179–185.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2.ª ed.). Springer.

Jolliffe, I. T. (2002). *Principal Component Analysis* (2.ª ed.). Springer.

Kaiser, H. F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, *20*(1), 141–151.

Kaufman, L., & Rousseeuw, P. J. (1990). *Finding Groups in Data*. Wiley.

Little, R. J. A., & Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3.ª ed.). Wiley.

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, *22*(158), 209–212.

Anexo A — Registo de achados (por gravidade)

#	Gravidade	Achado	Evidência / localização no R5
1	**Alta**	Classificação de novos clientes não abordada	Objetivo da empresa (enunciado §1); R5 só tem K-means e PCA descritivos.
2	**Alta**	Afirmação errada: a padronização "protege" de *outliers*	R5 §7.2 (Procedimento); *z-score* é linear.
3	**Alta**	Legenda da Fig. 1 contradiz a Tabela 10 (clusters 1 e 3)	Fig. 1 *vs.* Tabelas 7 e 10; proporções 22/48/30%.
4	**Alta**	Estrutura fraca omitida; k=3 contra o critério usado, sem validação	Tabela 8 (0,21–0,35); sem estabilidade.
5	**Média**	"Diferenças entre clusters" em categóricas sem evidência	R5 §7.6, sem tabela/teste.
6	**Média**	Sobre-interpretação do método de pagamento (p = 0,065) e tratamento desigual de $p \approx 0{,}09$	Tabela 5 e R5 §3.2.
7	**Média**	Conclusão causal/"demonstra" sobre abandono; sem ordem temporal nem validação preditiva	R5 §7.6 e Conclusões.
8	**Média**	MCAR não testado; 20 clientes excluídos com abandono ≈ 30%	R5 Tabela 1 e §2.2; dedução a partir de §7.6.
9	**Média**	"Valor" = rendimento/despesa do cliente; sem medida de valor para a empresa	R5 §3.1 Conclusão; Componente 1.
10	**Baixa**	V de Cramér da Região incorreto (0,039 → 0,067)	Tabela 5.
11	**Baixa**	Valores próprios somam 9,033; % variância somam 100,08%	Tabela 6.
12	**Baixa**	"*Loadings*" são vetores próprios; leitura sem limiar	Tabela 7.
13	**Baixa**	Cluster 3 "mais velho": idade igual à do Cluster 1	Tabela 10.
14	**Baixa**	Variáveis sem definição (*Perfil*, *Fidelização*, escalas, unidades); amostra não descrita	R5 §2.1.

Anexo B — Verificações numéricas realizadas pelo consultor

- **Tabela 5:** p-values recalculados a partir de χ^2 e graus de liberdade (todos conferem); $V = \sqrt{(\chi^2/n)}$ com n = 300: conferem 7 de 8 (Região: 0,067 *vs.* 0,039).
- **Tabela 6:** $\Sigma\lambda$ = 9,033 (esperado 9); $\lambda/9$ difere de percentagem reportada em CP1 (42,73 *vs.* 42,58) e CP2 (24,57 *vs.* 24,48); $\Sigma\%$ = 100,08. Bartlett recalculado ≈ 1286,6 (reportado 1295,6).
- **Tabela 7:** colunas com norma ≈ 1 e produto interno ≈ 0 (vetores próprios); correlações componente–variável = coeficiente × $\sqrt{\lambda}$.
- **Tabelas 2, 9 e 10:** médias ponderadas dos clusters ≈ médias globais (consistente).
- **Abandono por cluster:** n × taxa = 5,02; 7,97; 31,05 → 5, 8, 31 (total 44 em 280). χ^2 = 10,408; p = 0,0055; V = 0,193. Excluídos: 6 abandonos em 20; Fisher $p \approx 0{,}12$.
- **Figura 1:** proporção de pixels por cor (azul ≈ 49%, laranja ≈ 31%, verde ≈ 21%) *vs.* dimensões dos clusters (48%, 30%, 22%). Estimativa aproximada.