Faculdade de Economia · Universidade do Porto · 2026/2027

# Avaliação crítica do Relatório de Análise e Segmentação de Clientes

Parecer do consultor independente sobre o relatório R5

**Autor:** [Nome do estudante] — [N.º de estudante]

**Unidade curricular:** Análise de Dados

**Documento avaliado:** “Relatório de Análise e Segmentação de Clientes”, R5 (Relatório do Analista)

**Entrega:** 26 de outubro de 2026

## 1. Parecer em síntese

A empresa pediu três coisas: conhecer o perfil dos clientes, identificar segmentos distintos e dispor de um sistema para classificar novos clientes. O analista entregou uma análise descritiva, bivariada, uma PCA e uma segmentação por *K-means* sobre 300 clientes. Este parecer avalia o R5 segundo os três critérios do enunciado: **(A)** adequação das opções metodológicas, **(B)** qualidade da análise e da interpretação, **(C)** validade das conclusões e recomendações. Não reproduzi a análise: verifiquei a coerência interna dos números publicados (Anexo).

> **Resposta à questão central.** Os resultados **não constituem, por ora, uma base adequada** para segmentar clientes e classificar novos clientes. Servem como **hipótese de trabalho** credível, com um achado sólido (o abandono difere entre segmentos, $p = 0{,}0055$), mas assentam numa estrutura de grupos fraca, contêm um erro conceptual e inconsistências verificáveis, extrapolam em vários pontos e **nunca tratam a classificação de novos clientes**.

| Critério | Apreciação | Em uma linha |
|---|---|---|
| A. Adequação metodológica | **Parcial** | Escolhas convencionais e razoáveis, mas sem verificação de pressupostos nem análise de robustez; uma justificação metodológica errada. |
| B. Qualidade da análise e interpretação | **Parcial** | Cálculos de base coerentes; erros pontuais, figura inconsistente com tabela e interpretações mais fortes do que a evidência. |
| C. Validade das conclusões | **Insuficiente** | Das quatro conclusões centrais, uma é suportada, duas são só parcialmente suportadas e uma não tem suporte; falta o objetivo de classificação. |

## 2. Critério A — Adequação das opções metodológicas

A tabela resume cada opção do analista, a minha apreciação e a razão. “Adequada” significa que a opção é defensável para o objetivo; não significa que esteja isenta de reservas.

| Opção do R5 | Apreciação | Porquê | Alternativa / complemento |
|---|---|---|---|
| Eliminação *listwise* (280/300) | **Aceitável, não testada** | Perda de 6,7% é pequena, mas só é inócua se a falta for aleatória. Pelas taxas de abandono por cluster deduz-se que os 20 excluídos têm 6 abandonos (30%) contra 15,7% nos restantes (Fisher $p \approx 0{,}12$: sinal, não prova). Os 20 ficam sem segmento e a solução não serve para novos clientes. | Comparar excluídos e incluídos; imputação múltipla ou por vizinhos; análise de sensibilidade. |
| Todas as variáveis como contínuas | **Parcial** | Satisfação é ordinal, visitas/produtos/reclamações são contagens, % digital é limitada a [0;100]. A distância euclidiana e o Pearson assumem intervalos iguais. | Spearman; distância de Gower; transformações. |
| Correlação de Pearson | **Parcial** | Sensível a assimetria e extremos (rendimento e despesa têm cauda direita, máximos a 3,7 DP). Sem valores-*p*, intervalos nem diagramas de dispersão; mostram-se só as correlações “principais”. | Spearman ou log; gráficos; matriz completa em anexo. |

| | | | |
|---|---|---|---|
| Qui-quadrado + V de Cramér | **Adequada** | Teste apropriado para categóricas *vs.* abandono binário. Reservas: frequências esperadas não verificadas; oito testes sem correção (irrelevante aqui, pois nenhum é significativo). | Indicar *n* por categoria; teste exato se células pequenas. |
| PCA com Kaiser ($\lambda > 1$) | **Adequada, com reservas** | Quebra nítida entre $\lambda_2 = 2{,}21$ e $\lambda_3 = 0{,}83$ sustenta 2 componentes (67%). Kaiser é um critério simples e criticado; o *scree plot* é mencionado mas não mostrado. | Análise paralela (Horn); mostrar o *scree plot*. |
| Padronização antes do K-means | **Adequada…** | Necessária para variáveis em escalas diferentes. **…mas** a justificação de que protege dos extremos é **errada** (secção 3). | Log/*winsorização*; *k*-medoids (PAM). |
| K-means sobre 9 variáveis | **Parcial** | Quatro variáveis "de valor" correlacionadas (*r* até 0,84) pesam mais na distância; categóricas excluídas; inicializações e semente não indicadas (sem reprodutibilidade). | Usar scores da PCA ou selecionar variáveis; Gower/K-prototypes; repetições. |
| Escolha de $k = 3$ (silhueta máxima em $k = 2$) | **Insuficiente** | Critério de negócio é legítimo, mas há um só índice, nenhuma estabilidade, e todas as silhuetas (0,21–0,35) indicam estrutura fraca (Kaufman e Rousseeuw). $k = 4$ (0,319) quase empata e a Figura 1 do R5 sugere quatro nuvens. | *Elbow*, Calinski–Harabasz, *gap*; *bootstrap* (Rand ajustado); testar $k = 2$ e 4. |

### 2.1 Três opções que merecem uma explicação mais detalhada

**Valores em falta.** Faltam 9 rendimentos, 6 percentagens digitais e 6 satisfações; ficam 280 casos completos (93,3%). Eliminar os 20 clientes é defensável com perdas tão baixas, **mas só se a falta for aleatória**, o que o relatório não testa. O rendimento é uma variável sensível, em que a não-resposta pode depender do próprio valor. Há um indício que impede presumir inocuidade: o R5 indica taxas de abandono de 8,1%, 9,6% e 23,0% em clusters de 62, 83 e 135 clientes, o que corresponde a 5, 8 e 31 abandonos (cada taxa arredondada admite um único inteiro), isto é, 44 nos 280. Como no total há 50 abandonos, os 20 clientes excluídos incluem **6 abandonos (30%)**, contra 15,7% nos restantes. A diferença não é conclusiva (Fisher, $p \approx 0{,}12$, porque 20 casos são poucos), mas obrigava a verificar o mecanismo de falta. Além disso, 20 clientes ficam sem segmento e, para um cliente novo, a eliminação de casos não é utilizável.

**Padronização e valores extremos.** O R5 afirma que padronizar as variáveis "garante que a solução de K-means não seja afetada de forma relevante pelos valores extremos". É falso. O *z-score* é uma transformação linear, como passar metros para centímetros: não muda quem é o mais alto. O cliente com 5 544 € continua a 3,7 desvios-padrão da média e, como o K-means minimiza somas de distâncias ao quadrado, continua a puxar os centros. O cluster "de elevado valor" (rendimento médio 3 648 *vs.* terceiro quartil global 2 252) pode, em parte, estar a captar a cauda direita da distribuição. É uma hipótese que uma análise de sensibilidade (logaritmo, *winsorização*, *k*-medoids) permitiria verificar.

**Número de clusters.** O coeficiente de silhueta é máximo em $k = 2$ (0,353) e o analista escolhe $k = 3$ (0,325) por ser "mais diferenciado e interpretável". Um critério de negócio é legítimo, e o analista foi transparente. Mas a justificação é curta: usa-se um só índice, sem estabilidade; todas as silhuetas (0,21–0,35) caem na zona de estrutura fraca ou inexistente (Kaufman e Rousseeuw), o que as conclusões omitem ao falar de segmentos "distintos"; e $k = 4$ (0,319) quase empata com $k = 3$, sugerindo a Figura 1 do R5 quatro nuvens, com o grupo maior dividido em dois.

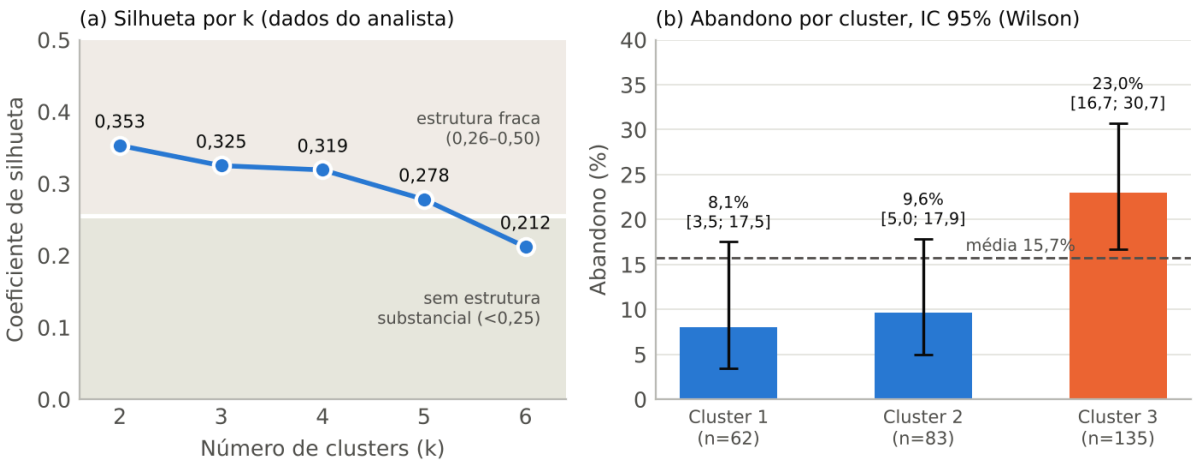



**Figura A.** (a) Silhueta por *k* com as faixas de Kaufman e Rousseeuw (1990). (b) Abandono por cluster com IC a 95% (Wilson), reconstruído a partir de *n* × taxa.

## 3. Critério B — Qualidade da análise e da interpretação

### 3.1 O que está bem feito

- O identificador foi excluído e as descritivas incluem *n*, quartis e valores em falta.
- As médias ponderadas dos clusters (Tabela 10) reproduzem as médias globais da Tabela 2: os cálculos de base são coerentes.
- Os valores-*p* da Tabela 5 e o teste cluster–abandono ($\chi^2 = 10{,}41$; $p = 0{,}0055$; V = 0,193) confirmam-se por recálculo.
- O analista foi transparente ao admitir que o maior coeficiente de silhueta ocorre em $k = 2$.

### 3.2 Erros e inconsistências verificáveis

| # | Problema | Evidência |
|---|---|---|
| 1 | **Afirmação errada:** padronizar "garante" que o K-means não é afetado por extremos | O *z-score* é uma transformação linear: os extremos mantêm-se a 3,7 DP (rendimento 5 544; despesa 241) e a soma de quadrados continua a penalizá-los. O cluster "de elevado valor" (rendimento médio 3 648 *vs.* Q3 global 2 252) pode estar a captar a cauda direita. |
| 2 | **Legenda da Figura 1 contradiz a Tabela 10** | O "Cluster 3" (verde) está no extremo direito do CP1 (rendimento, despesa, produtos, visitas elevados), perfil que a Tabela 10 atribui ao Cluster 1. As proporções de pixels (≈ 21/49/31%) coincidem com 62/135/83 clientes: indica rótulos 1 e 3 trocados (figura ou tabela). Estimativa aproximada. |
| 3 | V de Cramér da Região errado | √(1,364/300) = 0,067, não 0,039; as restantes sete linhas conferem. |
| 4 | Valores próprios incoerentes | Somam 9,033 (devia ser 9); CP1 = 3,846/9 = 42,73%, não 42,58%; percentagens somam 100,08%. |
| 5 | "*Loadings*" são vetores próprios | Colunas de norma ≈ 1 e ortogonais. As correlações componente–variável são coeficiente × √λ (p. ex. despesa–CP1 ≈ 0,90). |
| 6 | Descrição imprecisa do Cluster 3 | "Mais velhos": 47,9 anos *vs.* 47,2 no Cluster 1. Os Clusters 2 e 3 são quase iguais em rendimento, despesa e produtos; distinguem-se por idade, uso digital, antiguidade, satisfação e reclamações. |

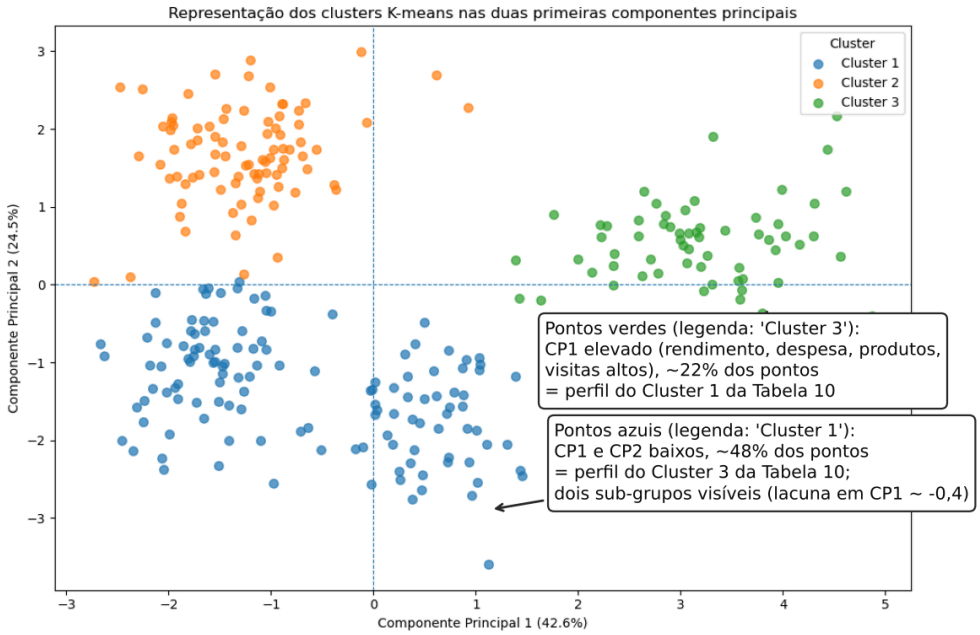



**Figura B.** Figura 1 do R5 com anotações do consultor. O grupo azul mostra uma lacuna em CP1 ≈ −0,4, compatível com $k = 4$.

### 3.3 Interpretações que vão além da evidência

Os problemas deste tipo têm uma causa comum: tratar como conclusão o que os números só permitem apresentar como pista. Cinco exemplos:

- **"Valor do cliente".** Rendimento e despesa do cliente não medem o valor para a empresa (receita, margem, CLV). A etiqueta é uma inferência.
- **Circularidade.** Os clusters são descritos com as variáveis que os definiram; as diferenças são grandes por construção. A Tabela 10 só mostra médias, sem dispersão.
- **Método de pagamento.** Com $p = 0{,}065$ e V = 0,155 não há significância, mas conclui-se que "poderá ser um fator relevante". Fidelização ($p = 0{,}088$) e Perfil ($p = 0{,}090$) não recebem o mesmo tratamento. É uma hipótese a testar, não uma conclusão.
- **Associação e causalidade no abandono.** O Cluster 3 tem 23,0% de abandono, mas 77% dos seus clientes não abandonaram: pertencer-lhe não prevê o abandono individual. E, se visitas, produtos, satisfação ou reclamações foram medidos durante ou após a decisão de sair, o perfil pode ser consequência e não causa.
- **Rótulos dos componentes.** "Valor" (CP1) e "modernização" (CP2) são leituras; a interpretação é seletiva (satisfação, 0,285, omitida do CP1 enquanto antiguidade, 0,298, é citada).

## 4. Critério C — Validade das conclusões

| Conclusão do R5 | Suportada? | Apreciação |
|---|---|---|
| Existem três segmentos distintos (valor elevado, jovens digitais, tradicionais) | **Parcialmente** | Os perfis médios são interpretáveis e coerentes, mas as silhuetas indicam estrutura fraca, $k$ não foi validado e o efeito dos extremos não foi testado. "Distintos" é demasiado forte. |
| O Cluster 3 é o segmento de maior risco de abandono (23,0% *vs.* 8,1% e 9,6%) | **Sim, como associação** | Confirmado ($p = 0{,}0055$). Mas 77% do Cluster 3 não abandonou, não há sensibilidade/AUC, o IC do Cluster 3 [16,7; 30,7] sobrepõe-se ao do Cluster 1 [3,5; 17,5], e desconhece-se a ordem temporal das medições (as variáveis podem refletir o abandono). "Demonstra" deve ser "sugere". |

| | | |
|---|---|---|
| Há diferenças entre clusters em grupo etário, plano e método de pagamento | **Não** | Sem tabela nem teste; o grupo etário deriva da idade (já usada); o plano não se relacionava com o abandono ($p$ = 0,994). |
| O método de pagamento pode ser fator relevante de retenção | **Não** | Associação não significativa ($p$ = 0,065), sem $n$ por categoria nem intervalos; tratamento desigual de $p \approx$ 0,09. |

Em suma, o único resultado inferencial sólido do R5 é a associação entre segmento e abandono; todo o resto é descrição, hipótese ou extrapolação. O IC do Cluster 3 [16,7; 30,7] sobrepõe-se parcialmente ao do Cluster 1 [3,5; 17,5], pelo que a diferença é plausível mas menos limpa do que "23% *vs.* 8%" sugere.

### Os resultados respondem ao problema da empresa?

| Objetivo da empresa | Cumprido? | Razão |
|---|---|---|
| Compreender o perfil dos clientes | **Em grande parte** | Descrição clara; reservas sobre extremos, tipos de variáveis e dados em falta. |
| Identificar segmentos distintos | **Parcialmente** | Hipótese interpretável, com estrutura fraca e validação em falta. |
| Sistema para classificar novos clientes | **Não** | Sem regra de atribuição (centróides e parâmetros de padronização), sem classificador supervisionado, sem validação em dados não vistos; a eliminação *listwise* é inaplicável a novos casos. As variáveis usadas (antiguidade, visitas, produtos, despesa, satisfação, reclamações) acumulam-se com o tempo e não existem à entrada: um cliente recém-chegado tenderia a parecer-se com o Cluster 2 (menor antiguidade e menos visitas) por ser recente e não pelo seu perfil (inferência, não cálculo). Com apenas 50 abandonos, a amostra limita modelos com muitos preditores. |

## 5. Limitações e recomendações

| Prioridade | Recomendação | Resolve |
|---|---|---|
| **1 · Imediata** | Corrigir figura/tabela (legendas dos clusters 1 e 3), a frase sobre extremos, o V da Região e os valores próprios; suavizar "demonstra". | Erros verificáveis (3.2) |
| **2 · Curto prazo** | Análises de robustez: log/*winsorização*, *k*-medoids, $k$ = 2/3/4, estabilidade por *bootstrap*, silhueta por cluster, comparação com *Perfil* A/B/C, imputação dos dados em falta. | Estrutura fraca e sensibilidade a extremos |
| **3 · Curto prazo** | Modelo supervisionado para classificar novos clientes (multinomial, árvore) com variáveis disponíveis à entrada, validação cruzada; modelo de risco de abandono com AUC e *recall*. | Objetivo não cumprido (secção 4) |
| **4 · Médio prazo** | Piloto de retenção dirigido ao segmento de maior abandono, com grupo de controlo; tratar o método de pagamento como hipótese. | Associação *vs.* causalidade |
| **5 · Estrutural** | Dicionário de dados (escalas, unidades, datas de medição), medida real de valor (margem/CLV), amostra maior, registo de *software*, semente e código. | Reprodutibilidade e qualidade dos dados |

**Limitações desta avaliação.** Trabalhei apenas com o relatório, sem os dados originais. Os 6 abandonos nos 20 excluídos resultam de *n* × taxa por cluster (cada taxa arredondada admite um único inteiro), e a deteção da troca de legendas usa também uma contagem aproximada de pixels. São indícios fortes, não prova; recomendo que o analista os confirme.

## 6. Conclusão

O R5 é um primeiro passo competente na descrição e produz uma associação segmento–abandono estatisticamente suportada. Contudo, a estrutura de grupos fraca, o erro sobre os valores extremos, a figura incoerente com a tabela, as conclusões não suportadas e a ausência de um sistema de classificação impedem-no de ser, hoje, uma base adequada para decidir. Recomendo à administração usá-lo como hipótese, exigir as correções e as análises de robustez e encomendar um modelo de classificação validado antes de qualquer decisão operacional.

## Referências


Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate Data Analysis* (8.ª ed.). Cengage.

Hennig, C. (2015). What are the true clusters? *Pattern Recognition Letters, 64*, 53–62.

Horn, J. L. (1965). A rationale and test for the number of factors in factor analysis. *Psychometrika, 30*(2), 179–185.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2.ª ed.). Springer.

Jolliffe, I. T. (2002). *Principal Component Analysis* (2.ª ed.). Springer.

Kaiser, H. F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement, 20*(1), 141–151.

Kaufman, L., & Rousseeuw, P. J. (1990). *Finding Groups in Data*. Wiley.

Little, R. J. A., & Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3.ª ed.). Wiley.

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212.


## Anexo — Verificações numéricas

- **Tabela 5:** p-values recalculados (todos conferem); V = √(χ²/*n*), *n* = 300: 7 de 8 conferem (Região: 0,067 *vs.* 0,039).
- **Tabela 6:** Σλ = 9,033; λ/9 ≠ percentagem reportada em CP1 (42,73 *vs.* 42,58) e CP2 (24,57 *vs.* 24,48); Σ% = 100,08. Bartlett recalculado ≈ 1 286,6 (reportado 1 295,6).
- **Tabela 7:** colunas com norma ≈ 1 e produto interno ≈ 0 (vetores próprios).
- **Tabelas 2, 9 e 10:** médias ponderadas dos clusters ≈ médias globais.
- **Abandono por cluster:** 5, 8 e 31 abandonos (total 44 em 280; 15,7%); excluídos: 6 em 20 (30%), Fisher $p \approx 0{,}12$; $\chi^2 = 10{,}408$, gl = 2, $p = 0{,}0055$, V = 0,193; IC de Wilson a 95%: [3,5; 17,5], [5,0; 17,9], [16,7; 30,7].
- **Figura 1:** proporção de pixels por cor ≈ 49% (azul), 31% (laranja), 21% (verde) *vs.* 48%, 30%, 22% (Tabela 9). Estimativa aproximada.
- Código: `verificacoes.py`.